제6장 학습이란 무엇인가 — 손실함수와 경사하강법

https://www.youtube.com/watch?v=aircAruvnKk

학습 목표

- 모델이 "틀렸다"는 것을 어떻게 아는지 손실함수로 설명한다
- 분류 문제에서 교차 엔트로피가 정답 쪽 확률이 낮을수록 손실을 키운다는 것을 설명하고, 확률 하나로 손실을 계산한다
- 회귀 문제에서는 평균제곱오차를 쓴다는 것을 안다
- 기울기가 알려주는 것이 무엇인지, 경사하강법의 갱신 규칙 한 줄을 읽는다
- 역전파가 출력 쪽에서 입력 쪽으로 곱셈을 이어 가며 가중치마다 기울기를 구하는 과정을 숫자로 따라간다
- 학습률이 너무 작을 때와 너무 클 때 손실 곡선이 어떻게 달라지는지 구분한다
- epoch와 batch를 가중치 갱신 횟수로 환산한다

4장 실습에서 로지스틱 회귀는 `수면시간 = -1.59 x 공부시간 + 13.96` 이라는 선을 내놓았다. -1.59와 13.96을 정한 것은 사람이 아니다. 모델이 훈련 데이터 112명을 보며 스스로 고른 값이다. 이번 장은 그 고르는 과정을 연다. 필요한 것은 두 가지다. 지금 얼마나 틀렸는지 재는 자(손실함수), 그리고 어느 쪽으로 값을 옮겨야 하는지 정하는 규칙(경사하강법)이다.

이 장은 개념 하나를 설명한 바로 뒤에 그 개념을 확인하는 실습을 둔다. 3절의 갱신 규칙은 실습 6.1에서, 학습률과 5절의 에포크는 실습 6.2에서 실행해 본다.

실행 환경

```
cd practice/chapter6
python -m pip install -r ../requirements.txt
```

필요한 패키지는 numpy, pandas, matplotlib이다. GPU는 필요 없다. 두 실습 모두 노트북에서 몇 초 안에 끝난다.

실습 6.2의 데이터는 **컴퓨터로 만든 합성 데이터**다. 실제 관측 자료가 아니다.

1. 모델은 어떻게 "틀렸다"는 것을 아는가

저 두 숫자를 사람이 손으로 맞춘다면 어떻게 할지 먼저 적어 본다. 4장 실습에서 `MY_TREE_DEPTH`를 바꿔 가며 정확도를 확인한 것과 같은 방식이다.

1. 값을 하나 정한다

2. 실행해서 정확도를 본다
3. 정확도가 낮으면 값을 조금 옮긴다
4. 다시 실행한다

기계가 이 일을 대신하려면 2번과 3번이 걸린다.

○ **2번이 걸리는 이유** — 기계는 "낮다"를 모른다

- 사람은 0.938이라는 숫자를 보고 "아직 부족하다"고 판단한다
- 기계에게는 판단할 기준이 없다. 낮을수록 좋은 숫자 하나를 정해 줘야 한다
- 그 숫자를 **손실(loss)** 이라고 부른다

○ **3번이 걸리는 이유** — 기계는 "어느 쪽"을 모른다

- 사람은 그림을 보고 선을 왼쪽으로 옮길지 오른쪽으로 옮길지 정한다
- 기계에게는 그림이 없다. 방향을 알려주는 숫자가 필요하다
- 그 숫자를 **기울기(gradient)** 라고 부른다

이 장의 나머지는 두 숫자를 만드는 방법이다. 손실을 2절에서, 기울기를 3절에서 다룬다.

○ **왜 정확도를 그대로 쓰지 않는가**

- 정확도는 맞힌 개수를 세는 값이라 계단처럼 움직인다. 선을 아주 조금 옮겨도 맞힌 개수는 그대로다
- 그러다 어느 지점에서 한 명이 넘어가면 한 칸 뛴다. 이런 값으로는 "조금 옮기면 조금 좋아진다"를 알 수 없다
- 손실은 조금 옮기면 조금 변하도록 만든다. 그래야 기계가 방향을 잡는다

---

2. 손실함수 — 틀린 정도를 숫자 하나로 모은다

2-1. 정답 쪽 확률에 −log를 씌운다

4장의 로지스틱 회귀는 학생마다 "시험을 통과할지"를 맞혔다. 답을 바로 내지 않고, 시그모이드(5장 3절)를 거쳐 0과 1 사이의 값을 먼저 계산한다. 이 값을 통과할 **확률**로 읽고, 0.5를 넘으면 통과로 판정한다.

손실함수(loss function)는 예측이 정답에서 얼마나 벗어났는지를 숫자 하나로 만드는 계산이다. 모델이 확률을 내놓는 분류 문제에서 가장 많이 쓰는 손실함수가 **교차 엔트로피(cross-entropy)** 다. 계산은 두 단계다.

```
1. 정답 쪽에 준 확률 p를 고른다   (정답이 통과면 통과 확률, 탈락이면 탈락 확률)
2. 손실 = -log(p)                  (log는 자연로그)
```

학생이 여러 명이면 학생마다 손실을 구해 평균 낸다. 4장의 scikit-learn 로지스틱 회귀도 이 평균을 줄이는 쪽으로 −1.59와 13.96을 골랐다. 기본 설정에서는 값이 지나치게 커지지 않게 막는 항이 하나 더 붙지만, 중심은 교차 엔트로피다.

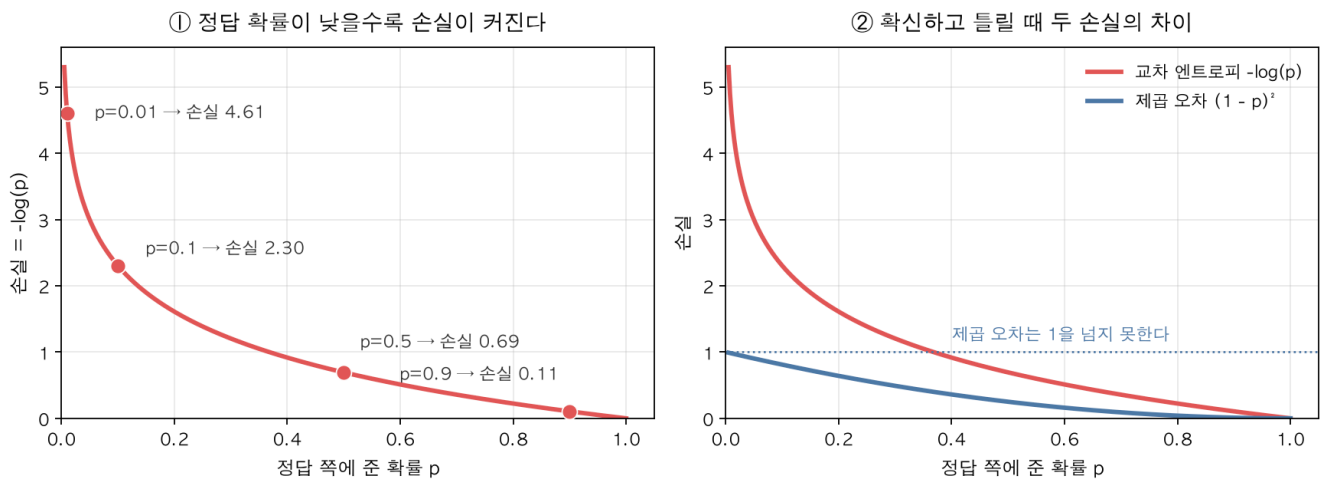


그림 6.1 왼쪽은 정답 쪽에 준 확률 p와 손실 –log(p)의 관계다. 오른쪽은 같은 p에서 제곱 오차 $(1 - p)^2$와 교차 엔트로피를 나란히 그렸다

p 값 네 개를 넣어 계산하면 이렇게 나온다.

정답 쪽 확률 p	교차 엔트로피 -log(p)	제곱 오차 (1-p)^2
0.9	0.105	0.010
0.5	0.693	0.250
0.1	2.303	0.810
0.01	4.605	0.980

출처: `practice/chapter6/results/6-0-concept-figures.log`

○ 정답에 높은 확률을 주면 손실이 0에 가깝다

- p = 0.9일 때 손실은 0.105다. p = 1이면 –log(1) = 0이다
- 정답 쪽 확률을 0.9에서 0.5로 낮추면 손실은 0.693이 된다
- 0.5는 "통과인지 탈락인지 모르겠다"는 확률이다. 실습 6.2는 w와 b를 0에서 출발시켜 모든 학생에게 0.5를 주므로, 처음 손실이 0.6931이다

○ 용어 정리

- **손실(loss)** — 지금 모델이 얼마나 틀렸는지를 나타내는 숫자 하나. 작을수록 좋다
- **손실함수(loss function)** — 그 숫자를 만드는 계산 방법
- 4장의 정확도는 클수록 좋았지만, 손실은 **작을수록** 좋다. 방향이 반대다

2-2. 확신하고 틀리면 손실이 끝없이 커진다

○ p가 0에 가까워질수록 손실이 커진다

- 통과한 학생에게 통과 확률 0.01을 주었다면, 탈락이라고 99% 확신하고 틀린 것이다

- 이때 교차 엔트로피는 4.605다. p를 0에 더 가깝게 줄이면 손실은 끝없이 커진다
- 같은 경우 제곱 오차는 0.980이다. p가 0이 되어도 $(1 - 0)^2 = 1$을 넘지 못한다

○ **그래서 분류에서는 제곱 오차 대신 교차 엔트로피를 쓴다**

- 그림 6.1 오른쪽에서 p가 0 쪽으로 갈 때 빨간 곡선은 가파르게 올라가고, 파란 곡선은 1 아래에서 완만하다
- 3절에서 볼 경사하강법은 곡선이 가파를수록 가중치를 크게 옮긴다
- 교차 엔트로피를 쓰면 크게 틀린 예측이 있을 때 가중치가 크게 고쳐진다. 제곱 오차를 쓰면 같은 경우에도 조금만 고쳐진다

○ **1절의 정확도 문제도 풀린다**

- 정확도는 맞힌 개수를 세서 계단처럼 움직였다
- 교차 엔트로피는 확률이 0.50에서 0.51로 바뀌면 손실도 그만큼 조금 바뀐다. 판정이 바뀌지 않아도 손실은 변하므로, 기계가 방향을 잡을 수 있다

2-3. 범주가 많아도 계산은 같다 — 숫자 분류와 언어모델

○ **범주가 열 개일 때**

- 9장의 숫자 0~9 분류처럼 범주가 열 개여도 계산 방법은 같다. 정답 범주에 준 확률 하나를 골라 −log를 씌운다
- 범주마다 확률을 나눠 주는 계산(소프트맥스)이 따로 있지만, 이 수업에서는 이름만 알아 둔다

○ **텍스트 언어모델도 같은 손실을 쓴다**

- 언어모델은 문장 다음에 올 토큰(단어 조각) 하나를 고른다. 후보는 모델이 아는 토큰 목록 전체로, 수만 개가 넘는다
- 즉 범주가 수만 개인 분류다. 실제로 다음에 나온 토큰에 준 확률에 −log를 씌우고, 문장의 토큰마다 구해 평균 낸다
- 4장의 통과 예측, 9장의 숫자 분류, 언어모델의 다음 토큰 예측이 모두 이 장의 교차 엔트로피로 학습한다

2-4. 회귀에서는 평균제곱오차를 쓴다

키나 가격처럼 숫자 하나를 맞히는 회귀 문제에는 "정답 쪽 확률"이 없다. 이때는 예측과 정답의 차이를 직접 잰다. 가장 많이 쓰는 것이 **평균제곱오차(MSE, mean squared error)** 다.

```
1. 차이   = 정답 − 예측              (점마다 하나씩)
2. 제곱   = 차이 × 차이              (점마다 하나씩)
3. 평균   = 제곱한 값을 다 더하고 개수로 나눈다
```

점 다섯 개의 차이가 −0.5, +0.8, −0.5, +1.0, −0.1이면 제곱은 0.25, 0.64, 0.25, 1.00, 0.01이고, 평균은 0.43이다.

출처: `practice/chapter6/results/6-0-concept-figures.log`

○ 제곱하는 이유는 두 가지다. 위로 빗나간 차이와 아래로 빗나간 차이가 서로 상쇄하지 않게 부호를 없애고, 크게 틀린 점에 더 무거운 벌을 준다

○ 7장 실습 7.1은 곡선의 차수를 바꿔 가며 점에 맞추고, 평균제곱오차의 제곱근(RMSE)으로 오차를 잰다

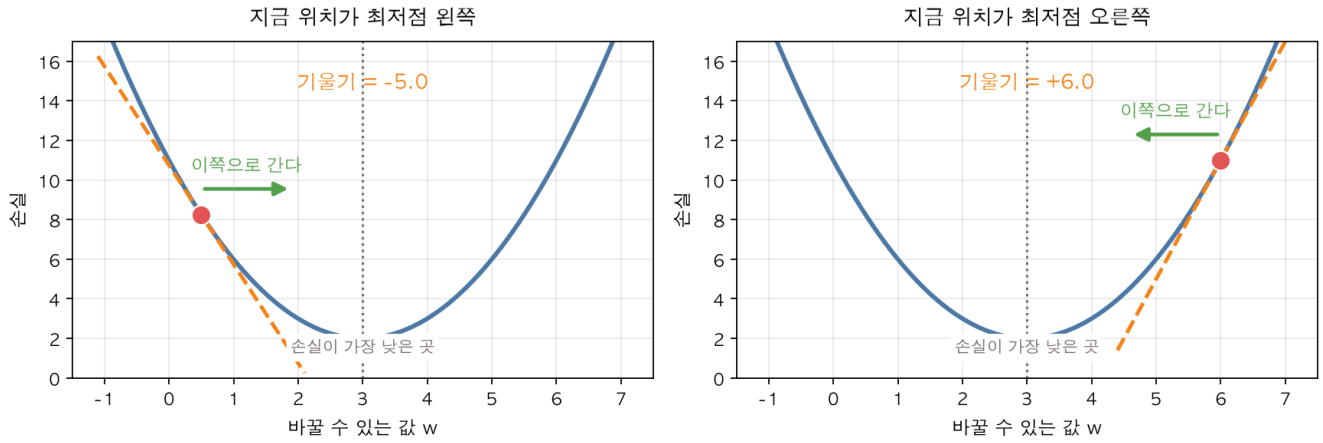
3. 기울기를 보고 내려간다

3-1. 기울기는 방향을 알려주는 화살표

이제 손실이라는 숫자가 생겼다. 남은 문제는 이것이다. **값을 어느 쪽으로 옮겨야 손실이 줄어드는가.**

바꿀 수 있는 값을 w 하나라고 두자. w를 가로축, 손실을 세로축에 놓으면 곡선이 하나 그려진다. 우리가 하려는 일은 이 곡선에서 가장 낮은 지점을 찾는 것이다.

한 걸음 = 기울기가 알려준 반대 방향으로, 학습률만큼



새 위치 = 지금 위치 - 학습률 × 기울기　　(기울기가 양수면 왼쪽, 음수면 오른쪽)

그림 6.2 지금 서 있는 자리에서 곡선이 어느 쪽으로 기울었는지 보면(주황 점선), 내려갈 방향이 정해진다

기울기는 지금 서 있는 자리에서 곡선이 얼마나, 어느 쪽으로 기울었는지를 나타내는 숫자다. 수학에서는 미분으로 구하지만, 지금은 화살표 하나로 이해하면 된다.

○ **기울기가 양수** — 오른쪽으로 갈수록 손실이 커진다

- 그림 6.2 오른쪽 그림이 그렇다. 기울기가 +6.0이다
- 손실을 줄이려면 **왼쪽**으로 가야 한다

○ **기울기가 음수** — 오른쪽으로 갈수록 손실이 작아진다

- 그림 6.2 왼쪽 그림이 그렇다. 기울기가 –5.0이다
- 손실을 줄이려면 **오른쪽**으로 가야 한다

○ **기울기가 0** — 어느 쪽으로 가도 손실이 그대로다

- 곡선의 바닥에 도착했다는 뜻이다. 더 갈 곳이 없다

정리하면 이렇다. **기울기의 반대 방향으로 가면 손실이 줄어든다.** 이것이 경사하강법(gradient descent)의 전부다.

3-2. 갱신 규칙 한 줄

방향이 정해졌으니 얼마나 갈지만 정하면 된다. 그 값이 **학습률(learning rate)** 이다. 학습률은 데이터에서 배우는 값이 아니라 사람이 미리 정하는 값이다. 이런 값을 **하이퍼파라미터(hyperparameter)** 라고 부른다. 학습률을 너무 작게 또는 너무 크게 잡으면 어떻게 되는지는 실습 6.2에서 다룬다.

```
새 w = 지금 w − 학습률 × 기울기
```

이 한 줄이 딥러닝 학습의 심장이다. 층이 백 개인 신경망도 가중치 하나하나에 이 규칙을 그대로 적용한다.

○ 부호가 저절로 맞는다

- 기울기가 양수면 학습률 × 기울기도 양수이고, 빼면 w가 작아진다. 즉 왼쪽으로 간다
- 기울기가 음수면 빼는 값이 음수라 w가 커진다. 즉 오른쪽으로 간다
- 방향을 따로 판단할 필요가 없다. 빼기 한 번으로 해결된다

○ 바닥에 가까워지면 걸음이 저절로 줄어든다

- 곡선의 바닥 근처는 평평하다. 평평하면 기울기가 0에 가깝다
- 기울기가 작으면 학습률 × 기울기도 작아져서 조금만 움직인다
- 멀리 있을 때는 성큼성큼, 가까워지면 살금살금 움직인다. 이 성질을 바로 다음 실습 6.1의 표에서 숫자로 확인한다

실습 6.1: 손실 곡선 위를 한 걸음씩 내려간다

실습 목표

- 갱신 규칙 한 줄이 실제로 어떤 숫자를 만들어 내는지 걸음마다 확인한다
- 바닥에 가까워질수록 걸음이 짧아지는 것을 숫자로 본다
- 출발점과 걸음 수를 바꾸면 궤적이 어떻게 달라지는지 눈으로 비교한다

데이터

이 실습에는 데이터가 없다. 손실 곡선을 식으로 직접 준다.

```
손실(w) = (w − 3)² + 2
```

이 곡선은 w = 3에서 가장 낮고, 그때 손실은 2다. 답을 우리가 이미 알고 시작한다. 알고 시작하는 이유는, 기계가 그 답을 **어떻게** 찾아가는지 걸음마다 대조하기 위해서다.

교차 엔트로피로 만든 손실 곡선도 바닥 근처에서는 이런 그릇 모양이다. 이 실습은 갱신 규칙만 떼어 보려고 가장 단순한 그릇 모양 식을 쓴다. scikit-learn을 쓰지 않고 numpy로 직접 계산해 식이 코드에 그대로 보이게 했다.

실행 명령

```
cd practice/chapter6/code
python 6-1-gradient-descent.py
```

핵심 코드

파일 맨 위에 학생이 바꿀 세 줄이 있다.

```
LEARNING_RATE = 0.1     # 한 걸음의 보폭을 정하는 값
START_W = -2.0          # 어디에서 출발할 것인가
N_STEPS = 15            # 몇 걸음 걸을 것인가
```

기울기를 구하는 부분과 한 걸음 걷는 부분은 다음과 같다.

```
def gradient(w: float) -> float:
    # 손실(w) = (w - 3)^2 + 2 를 w로 미분하면 2 * (w - 3) 이 된다.
    return 2.0 * (w - TRUE_BEST_W)

current_grad = gradient(w)
stride = learning_rate * current_grad      # 이번 걸음에서 움직이는 거리
next_w = w - stride
```

전체 코드는 `practice/chapter6/code/6-1-gradient-descent.py` 참고

실행 결과

아래는 기본값(`LEARNING_RATE = 0.1`, `START_W = -2.0`, `N_STEPS = 15`)으로 실행한 로그다.

```
손실 곡선: 손실(w) = (w - 3)^2 + 2
갱신 규칙: 다음 w = 지금 w - 학습률 x 기울기
학습률 0.1, 출발 w = -2.0, 15걸음

=== 걸음마다의 기록 ===
 걸음          w          손실          기울기          이동거리          다음w
  0     -2.000       27.000      -10.000        1.000     -1.000
  1     -1.000       18.000       -8.000        0.800     -0.200
  2     -0.200       12.240       -6.400        0.640      0.440
  3      0.440        8.554       -5.120        0.512      0.952
  4      0.952        6.194       -4.096        0.410      1.362
  5      1.362        4.684       -3.277        0.328      1.689
 ...
 13      2.725        2.076       -0.550        0.055      2.780
 14      2.780        2.048       -0.440        0.044      2.824
 15      2.824        2.031       -0.352        0.035      2.859

=== 처음과 끝 비교 ===
출발: w = -2.000, 손실 = 27.000
도착: w = 2.824, 손실 = 2.031
가장 낮은 곳: w = 3.000, 손실 = 2.000
아직 남은 거리: 0.176
```

출처: `practice/chapter6/results/6-1-gradient-descent.log`

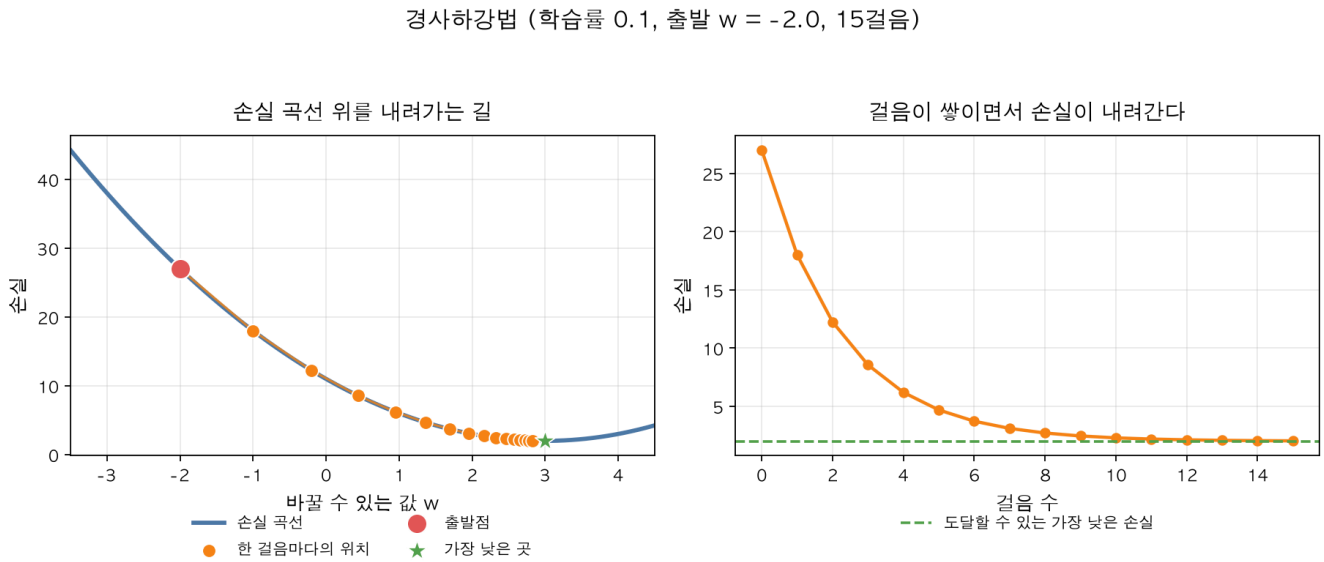


그림 6.3 왼쪽은 손실 곡선 위를 내려가는 궤적, 오른쪽은 걸음이 쌓이면서 손실이 내려가는 모습이다. 초록 별이 가장 낮은 곳이다

결과 읽기

○ 첫 걸음이 가장 크다

- 0걸음에서 기울기가 −10.000이고 이동거리가 1.000이다
- 15걸음에서는 기울기가 −0.352, 이동거리가 0.035다. 첫 걸음의 29분의 1 수준이다
- 학습률은 0.1로 처음부터 끝까지 그대로였다. 걸음이 짧아진 것은 기울기가 작아졌기 때문이다

○ 기울기가 전부 음수다

- 출발점 −2.0이 최저점 3.0의 왼쪽에 있어서 오른쪽으로 가야 한다
- 갱신 규칙에서 음수를 빼니 w가 커진다. −2.000 → −1.000 → −0.200 → 0.440으로 오른쪽으로 이동한다
- 방향을 사람이 알려주지 않았다. 기울기의 부호가 정했다

○ 손실이 27.000에서 2.031로 내려갔다

- 도달할 수 있는 가장 낮은 손실은 2.000이다. 차이가 0.031 남았다
- w는 2.824까지 왔고 목표 3.000까지 0.176이 남았다
- 15걸음으로는 정확히 도착하지 못한다. 대신 매 걸음 조금씩 가까워진다

○ 그림 6.3 왼쪽에서 점 간격을 본다

- 왼쪽 위 출발점 근처에서는 점이 듬성듬성하다
- 바닥 근처에서는 점이 촘촘히 뭉쳐 있다
- 같은 규칙, 같은 학습률인데 걸음의 길이만 저절로 달라졌다

해 보기

`START_W`와 `N_STEPS`를 바꿔 다시 실행하고, 그림 6.3과 표를 비교한다. `LEARNING_RATE`는 0.1로 둔다. 학습률은 실습 6.2에서 바꿔 본다.

1. `START_W = 8.0`으로 바꾼다. 기울기의 부호가 바뀌는지, w가 어느 쪽으로 움직이는지 확인한다
2. `START_W = 3.0`으로 바꾼다. 첫 걸음의 기울기와 이동거리가 얼마인지 확인한다
3. `START_W = -2.0`으로 되돌리고 `N_STEPS = 50`으로 늘린다. 50걸음 뒤 w가 3.000에 얼마나 가까워지는지 확인한다

○ 1번에서 기울기 부호가 바뀌는데도 코드는 한 줄도 고치지 않았다. 갱신 규칙이 방향을 스스로 처리한다는 뜻이다

○ 2번은 바닥에서 출발한 경우다. 3-1절에서 기울기가 0이면 더 갈 곳이 없다고 한 것을 숫자로 확인한다

---

4. 층이 여러 개면 — 역전파

갱신 규칙을 쓰려면 가중치마다 기울기가 하나씩 있어야 한다. 실습 6.1은 가중치가 w 하나라 기울기 식을 손으로 적을 수 있었다. 5장의 다층 퍼셉트론은 층마다 가중치가 있고, 앞 층 가중치가 바뀌면 뒤 층 계산이 줄줄이 바뀐다. 가중치마다 식을

따로 세우기 어렵다.

역전파(backpropagation) 는 이 기울기를 한 번에 구하는 계산 순서다. 가장 작은 예로 따라간다. 입력 x에 가중치 두 개를 차례로 곱하고, 시그모이드로 통과 확률을 낸 뒤, 2절의 교차 엔트로피로 손실을 잰다.

```
h    = x × w1            (첫 번째 층)
z    = h × w2            (두 번째 층)
p    = 시그모이드(z)      (통과 확률)
손실 = -log(p)           (정답이 통과일 때)
```

x = 2, w1 = 0.5, w2 = –1로 두고, 정답은 통과로 둔다.

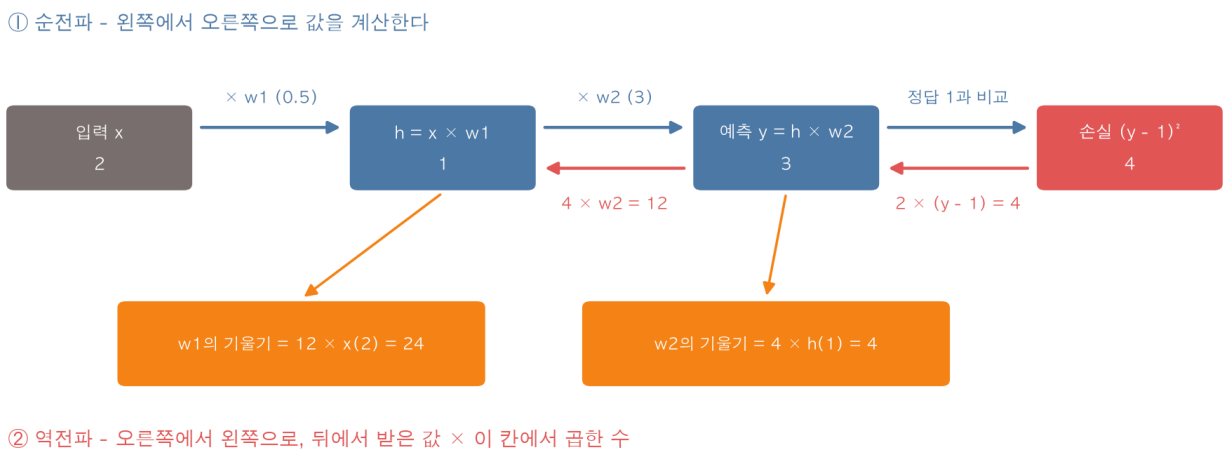


그림 6.4 윗줄 파란 화살표는 값을 왼쪽에서 오른쪽으로 계산하는 순전파다. 빨간 화살표는 오른쪽에서 왼쪽으로 기울기를 넘기는 역전파이고, 주황 상자가 각 가중치의 기울기다

○ 1단계 순전파 — 앞에서부터 값을 계산한다

- h = 2 × 0.5 = 1, z = 1 × (–1) = –1, p = 시그모이드(–1) = 0.269, 손실 = –log(0.269) = 1.313
- 정답이 통과인데 통과 확률을 0.269만 줬다. 틀린 쪽으로 기운 예측이다
- 계산한 값 h, z, p를 지우지 않고 둔다. 2단계에서 쓴다

○ 2단계 역전파 — 뒤에서부터 "손실이 이 값에 얼마나 민감한가"를 넘긴다

- 맨 끝: 손실이 z에 얼마나 민감한가는 **p – 정답**이다. 정답 통과를 1로 두면 0.269 – 1 = –0.731이다
- 시그모이드와 교차 엔트로피를 이어 붙이면 맨 끝 값이 이렇게 뺄셈 하나로 줄어든다. 유도에는 미분이 필요해 생략하고, 아래 수치 확인으로 맞는지 본다
- 음수라는 것은 z를 키우면 손실이 줄어든다는 뜻이다. z를 키우면 통과 확률이 올라가므로 맞는 방향이다
- 한 칸 앞으로: z = h × w2이므로 h가 조금 바뀌면 z는 그 w2배만큼 바뀐다. 그래서 손실이 h에 민감한 정도는 –0.731 × w2 = –0.731 × (–1) = 0.731이다
- 규칙은 하나다. **뒤에서 받은 값 × 이 칸에서 곱한 수**

○ 가중치의 기울기 — 그 가중치에 곱해진 입력을 곱한다

- w2는 h와 곱해졌다. w2의 기울기 = (z에서 받은 값 −0.731) × h(1) = −0.731
- w1은 x와 곱해졌다. w1의 기울기 = (h에서 받은 값 0.731) × x(2) = 1.462
- 3-2절의 갱신 규칙을 적용하면 기울기가 음수인 w2는 커지고, 양수인 w1은 작아진다. 두 변화 모두 z를 키워 통과 확률을 올린다

○ **계산이 맞는지 직접 확인한다**

- 역전파로 구한 w1의 기울기 1.462는 "w1을 아주 조금 키우면 손실이 그 1.462배만큼 커진다"는 뜻이다
- 코드에서 w1과 w2를 각각 0.001만큼 키우고 손실을 다시 계산해, 손실 변화를 0.001로 나눠 보았다

```
수치 확인: 가중치를 0.001 키웠을 때 (손실 변화 ÷ 0.001)
        w1: 1.463  (역전파 값 1.462)
        w2: -0.731  (역전파 값 -0.731)
```

출처: `practice/chapter6/results/6-0-concept-figures.log`

- 직접 바꿔 본 값이 역전파 값과 소수점 둘째 자리까지 같다. 남은 차이는 0.001이 0이 아니라서 생긴다

○ **층이 많아도 같은 일을 반복한다**

- 층이 열 개면 순전파로 열 칸을 계산하고, 역전파로 열 칸을 거꾸로 지나며 곱셈을 이어 간다
- 중간에 활성화 함수가 있으면 그 함수의 기울기를 한 번 더 곱한다. ReLU라면 켜졌을 때(입력이 양수일 때) 1, 꺼졌을 때 0을 곱한다
- 순전파 한 번, 역전파 한 번이면 모든 가중치의 기울기가 나온다. 가중치마다 계산을 따로 다시 돌리지 않는다
- 범주가 여러 개인 소프트맥스와 교차 엔트로피를 이어 붙여도 맨 끝 값은 "확률 − 정답" 꼴이다. 2-3절의 언어모델도 이 값에서 역전파를 시작한다
- 9장에서 쓰는 scikit-learn의 `MLPClassifier`는 이 역전파로 기울기를 구하고, 분류 손실로 2절의 교차 엔트로피를 쓴다. 학습 코드 한 줄 안에서 이 장의 계산이 반복된다

---

5. epoch와 batch

지금까지는 한 걸음 걷는 방법만 봤다. 실제 학습에서는 데이터가 여러 개이고, 그 데이터를 여러 번 반복해서 본다. 여기에 이름이 두 개 붙는다.

○ **에포크(epoch)** — 전체 데이터를 처음부터 끝까지 한 번 다 본 것

- 데이터가 1000개면, 1000개를 모두 한 번씩 쓴 시점이 1에포크다
- 에포크 10회는 같은 데이터를 열 번 반복해서 봤다는 뜻이다

○ **배치(batch)** — 가중치를 한 번 갱신하기 전에 묶어서 보는 데이터의 개수

- 배치 크기가 32면, 32개를 본 뒤 갱신 한 번, 다음 32개를 본 뒤 갱신 한 번 하는 식이다
- 배치 크기를 전체 데이터 개수와 같게 두면 에포크마다 갱신이 한 번뿐이다

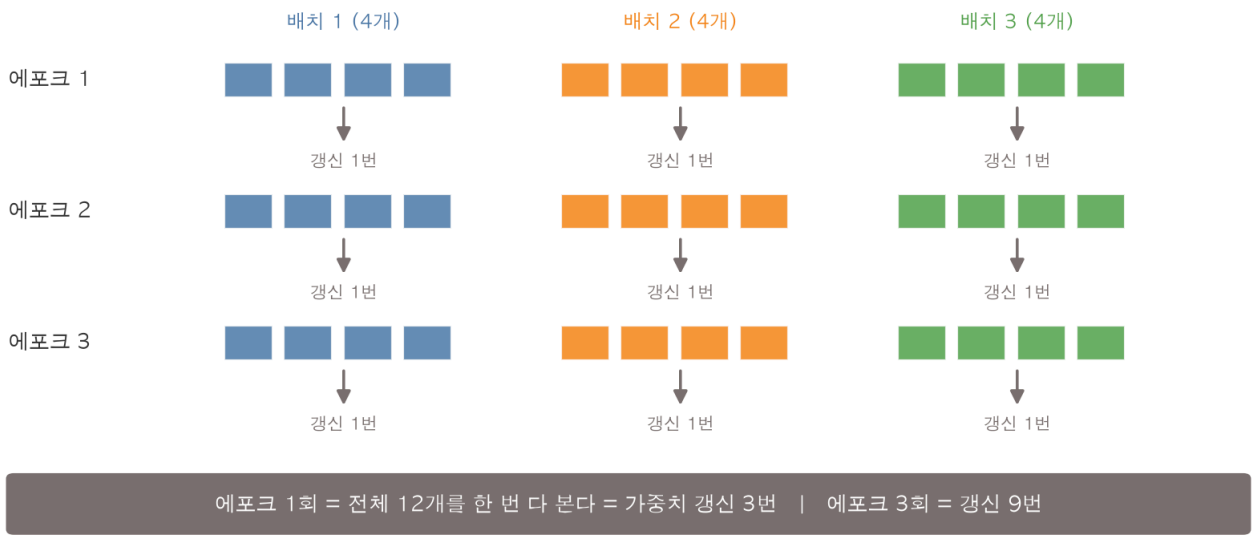


그림 6.5 데이터 12개를 배치 크기 4로 나누면 에포크 1회에 갱신이 3번 일어난다. 에포크 3회면 갱신 9번이다

갱신 횟수는 곱셈으로 나온다.

```
에포크당 갱신 횟수 = 전체 데이터 개수 ÷ 배치 크기
전체 갱신 횟수     = 에포크당 갱신 횟수 × 에포크 수
```

표 6.1 데이터 1000개일 때 설정에 따른 갱신 횟수

배치 크기	에포크	에포크당 갱신	전체 갱신
1000	10	1	10
100	10	10	100
10	10	100	1000

○ 배치 크기를 작게 하면

- 갱신이 자주 일어나서 같은 에포크 수로도 더 많이 움직인다
- 대신 한 번에 보는 데이터가 적어 방향이 들쭉날쭉해진다. 손실 곡선이 지그재그로 흔들린다

○ 배치 크기를 크게 하면

- 방향이 안정된다. 손실 곡선이 매끄럽다
- 대신 갱신이 드물고, 한 번에 계산할 양이 많아 메모리를 더 쓴다

○ 바로 다음 실습 6.2의 설정

- 실습 6.2는 배치를 나누지 않는다. 학생 200명을 한 번에 보고 갱신 한 번을 한다
- 그래서 에포크 200회 = 갱신 200번이다. 표 6.1의 첫 줄과 같은 구조다

실습 6.2: 학습률 셋으로 학습을 일부러 망가뜨린다

실습 목표

- 학습률 하나만 바꿨을 때 교차 엔트로피 손실 곡선이 얼마나 달라지는지 한 그림에서 비교한다
- 학습률이 너무 크면 손실이 처음보다 커지고 바닥 근처에 머물지 못하는 것을 확인한다
- 학습 곡선을 보고 학습률을 어느 쪽으로 고쳐야 하는지 판단한다

데이터

학생 200명을 만든다. 공부시간은 0~10시간 사이에서 고르고, 통과 확률 = 시그모이드(1.2 × 공부시간 − 6)에 따라 통과·탈락을 뽑았다. 통과한 학생은 98명이다. **컴퓨터로 만든 합성 데이터**이며 실제 관측 자료가 아니다.

모델은 통과 확률 = 시그모이드(w × 입력 + b)이고, w와 b 두 값을 경사하강법으로 찾는다. 손실은 2절의 교차 엔트로피다. 입력은 공부시간에서 5를 뺀 값이다. 5를 빼지 않으면 어떻게 되는지는 해 보기 3번에서 확인한다.

실행 명령

```
cd practice/chapter6/code
python 6-2-learning-rate.py
```

핵심 코드

파일 맨 위에서 학습률 세 개를 정한다.

```
LEARNING_RATES = [0.003, 0.3, 30.0]    # 너무 작다 / 알맞다 / 너무 크다
N_EPOCHS = 200                         # 전체 데이터를 몇 번 도는가
SHIFT_INPUT = True                     # True면 입력 = 공부시간 - 5, False면 공부시간 그대로
```

한 에포크에서 하는 일은 다섯 줄이다. 실습 6.1의 갱신 규칙을 w와 b 두 개에 각각 적용한 것이다.

```
p = sigmoid(w * x + b)                    # 학생마다 통과 확률
grad_w = float(np.mean((p - y) * x))      # w를 키우면 손실이 얼마나 커지는가
grad_b = float(np.mean(p - y))            # b를 키우면 손실이 얼마나 커지는가

w = w - learning_rate * grad_w
b = b - learning_rate * grad_b
```

`p - y`는 4절 역전파의 맨 끝 값 "p − 정답"이다. 학생마다 이 값을 구하고, w의 기울기는 여기에 입력 x를 곱해 평균 낸다.

전체 코드는 `practice/chapter6/code/6-2-learning-rate.py` 참고

실행 결과

```
=== 목적지 ===
w와 b로 도달할 수 있는 가장 낮은 손실: 0.2542
그때의 w = 1.3007, b = -0.0534, 정확도 = 0.905

=== 학습률별 결과 ===
   학습률     평가  처음 손실  마지막 손실  가장 높았던 손실  손실이 오른 에포크 수    찾은 w    찾은 b   정확도
 0.003 너무 작다 0.6931  0.3814     0.6931             0  0.4166 -0.0038 0.910
 0.300   알맞다 0.6931  0.2542     0.6931             0  1.3006 -0.0529 0.905
30.000 너무 크다 0.6931  1.0473     3.3057            73 10.6357  1.1509 0.900

=== 에포크별 손실 (일부만 뽑아 봄) ===
   에포크    lr=0.003      lr=0.3       lr=30
     0      0.6931      0.6931      0.6931
     1      0.6894      0.4192      3.3057
     2      0.6856      0.3502      3.0161
     3      0.6819      0.3194      2.7273
     5      0.6746      0.2909      2.1532
    10      0.6572      0.2678      0.7665
    20      0.6253      0.2576      0.8598
    50      0.5490      0.2543      0.2595
   100      0.4663      0.2542      0.4798
   200      0.3814      0.2542      1.0473
```

출처: `practice/chapter6/results/6-2-learning-rate.log`

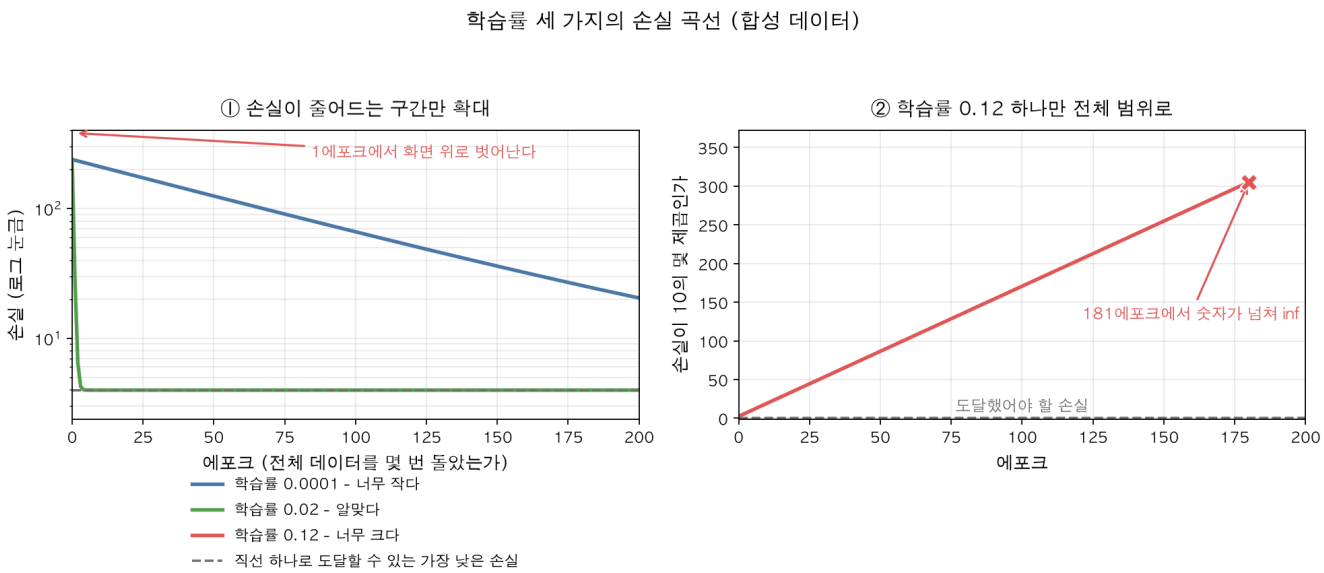


그림 6.6 왼쪽은 에포크별 손실이고, 회색 점선이 도달할 수 있는 가장 낮은 손실이다. 오른쪽은 200에포크 뒤 학습률마다 찾은 통과 확률 곡선과 학생 200명이다

결과 읽기

세 곡선은 모두 같은 자리(손실 0.6931)에서 출발했다. 2-1절에서 본 대로, 모든 학생에게 통과 확률 0.5를 준 상태의 손실이다. 200에포크 뒤 도착 지점만 다르다.

○ 학습률 0.3 — 50에포크 무렵 바닥에 닿았다

- 1에포크에서 0.6931 → 0.4192로 떨어졌다
- 50에포크에서 0.2543이다. 도달할 수 있는 가장 낮은 손실 0.2542와 0.0001 차이다
- 100에포크부터는 0.2542에서 움직이지 않는다. 찾은 w는 1.3006으로 목표 1.3007과 소수점 셋째 자리까지 같다
- 그림 6.6 왼쪽에서 초록 곡선이 회색 점선에 붙어 있는 구간이 이 상태다

○ 학습률 0.003 — 방향은 맞는데 진도가 안 나간다

- 손실이 0.6931에서 0.3814까지 내려갔다. 손실이 오른 에포크 수가 0이다. 한 번도 방향을 틀리지 않았다
- 그런데 목표는 0.2542다. 200에포크를 다 쓰고도 도착하지 못했다
- 찾은 w는 0.4166으로 목표 1.3007의 3분의 1 정도다. 그림 6.6 오른쪽에서 파란 곡선이 완만하게 누운 것이 이 때문이다

○ 학습률 30 — 첫 에포크부터 손실이 올라갔다

- 0에포크 0.6931에서 1에포크 3.3057로 커졌다. 한 걸음 만에 약 4.8배다
- 50에포크에 0.2595로 바닥 근처까지 왔다가 100에포크에 0.4798, 200에포크에 1.0473으로 다시 올라갔다
- 200에포크 중 73에포크에서 손실이 직전보다 커졌다. 그림 6.6 왼쪽의 빨간 톱니 모양이 이것이다
- 보폭이 너무 길어 바닥을 지나쳐 반대편 비탈에 착지하고, 거기서 다시 반대로 가다 또 지나치기 때문이다
- 찾은 w는 10.6357로 목표 1.3007의 8배가 넘는다. 오른쪽 빨간 곡선이 계단처럼 꺾인 것은 w가 지나치게 커서다. 모델이 공부시간 5시간 근처를 경계로 확률을 0과 1로 단정한다

○ **손실이 inf로 넘치지는 않았다**

- 200에포크 동안 가장 높았던 손실은 3.3057이다
- 교차 엔트로피 분류에서는 기울기의 재료인 p − 정답이 −1과 1 사이에 머문다. 그래서 한 걸음에 움직이는 거리에 상한이 있다
- 학습률이 커도 손실이 걸음마다 몇 배씩 불어나지 않고, 이 실습에서는 바닥 근처를 오르내렸다

○ **정확도는 세 학습률이 거의 같다**

- 정확도는 0.910, 0.905, 0.900이다. 손실은 0.3814와 0.2542로 크게 다른데 정확도는 오히려 학습률 0.003이 가장 높다
- 정확도는 확률이 0.5를 넘었는지만 센다. 0.51로 맞힌 것과 0.99로 맞힌 것을 구분하지 않는다
- 1절에서 학습에 정확도 대신 손실을 쓴다고 한 이유가 이것이다. 정확도만 보면 세 학습률의 차이가 보이지 않는다

○ **여기서 얻는 판단 기준**

- 손실이 첫 몇 에포크에 올라가면 학습률이 크다. 10분의 1로 줄인다
- 손실이 계속 내려가는데 끝까지 평평해지지 않으면 학습률이 작거나 에포크가 모자라다
- 손실이 어느 값에 붙어 더 안 내려가면 그 값이 이 모델이 도달할 수 있는 바닥이다. 학습률을 더 만져도 소용없다
- 알맞은 학습률을 정하는 공식은 없다. 이 실습처럼 10배, 100배씩 띄운 값 몇 개를 넣어 보고 손실 곡선을 비교한다

해 보기

`LEARNING_RATES`, `N_EPOCHS`, `SHIFT_INPUT`을 바꿔 다시 실행한다.

1. `[0.003, 0.3, 30.0]`의 첫 값을 `0.03`으로 올린다. 200에포크 안에 바닥 0.2542에 닿는지 확인한다
2. 마지막 값을 `3.0`으로 낮춘다. "손실이 오른 에포크 수" 열이 73에서 어떻게 바뀌는지 본다
3. `SHIFT_INPUT = False`로 바꾼다. 학습률 0.3의 마지막 손실이 0.2542에 닿는지, 손실 곡선 모양이 어떻게 달라지는지 확인한다
4. 학습률 0.003을 그대로 두고 `N_EPOCHS`만 2000으로 늘린다. 보폭이 짧아도 걸음 수로 메울 수 있는지 확인한다

○ 4번이 이 실습의 핵심 질문이다. 학습률과 에포크는 서로 맞바꿀 수 있는 값인지, 아니면 각자 다른 일을 하는지 판단해 본다

---

6. 학습 곡선 읽는 법

학습 곡선(learning curve) 은 가로축에 에포크, 세로축에 손실을 놓고 그린 그림이다. 학습이 잘 되고 있는지 이 그림 하나로 판단한다. 실습 6.2의 그림 6.6 왼쪽이 학습 곡선이다.

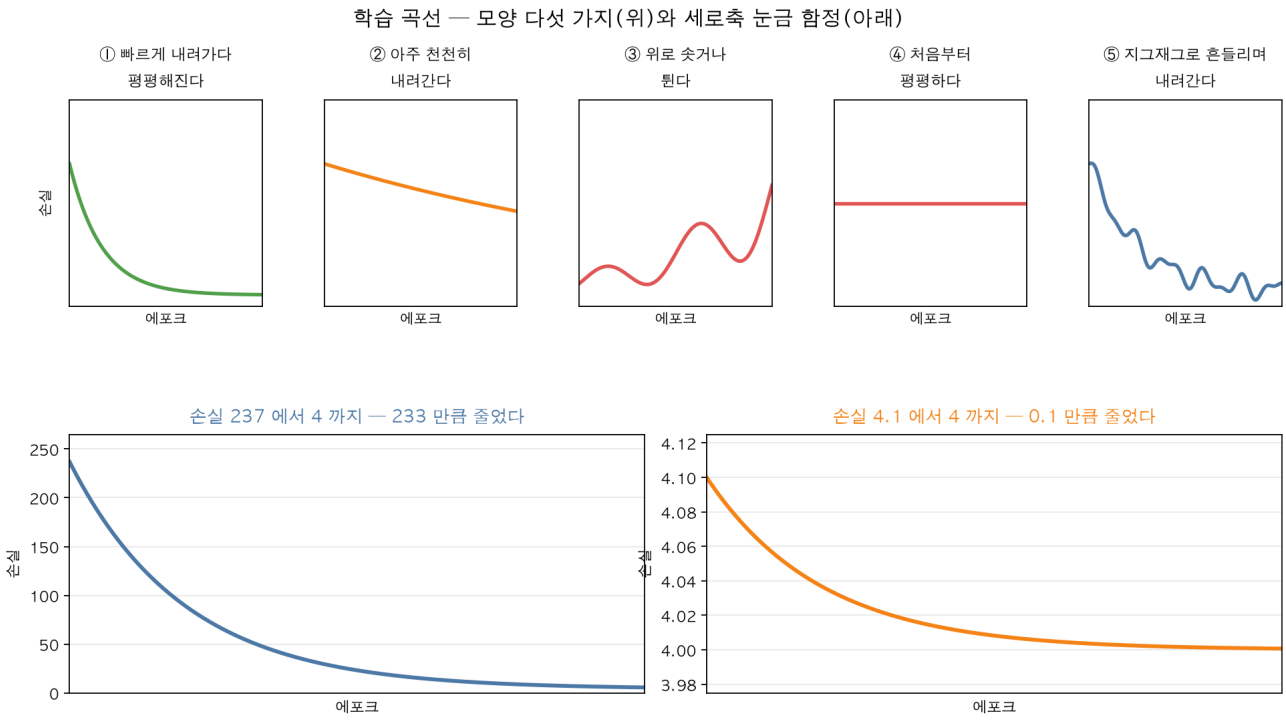


그림 6.7 윗줄 다섯 칸은 아래 표 6.2의 다섯 줄과 같은 순서다. 모양만 비교하려고 축에 숫자를 넣지 않았다. 아랫줄 두 칸은 모양이 같은 곡선 두 개인데, 왼쪽은 손실이 237에서 4까지 233만큼 내려갔고 오른쪽은 4.1에서 4.0까지 0.1만큼 내려갔다. 세로축 눈금을 읽지 않으면 두 곡선을 같은 성과로 본다.

표 6.2 곡선 모양별 진단

곡선 모양	무슨 일이 일어났는가	다음에 할 일
빠르게 내려가다 평평해진다	정상이다. 바닥에 닿았다	그대로 둔다. 더 돌려도 크게 안 변한다
아주 천천히 내려간다	학습률이 작거나 에포크가 모자라다	학습률을 키우거나 에포크를 늘린다
위로 솟거나 튄다	학습률이 크다	학습률을 10분의 1로 줄인다
처음부터 평평하다	갱신이 일어나지 않는다	학습률이 0에 가깝지 않은지, 데이터가 제대로 들어갔는지 본다
지그재그로 흔들리며 내려간다	배치 크기가 작을 때 흔히 나타난다	전체 방향이 아래로 향하면 문제로 보지 않는다

○ 실습 6.2의 곡선을 표에 대 본다

- 학습률 0.3의 초록 곡선은 첫 줄, 0.003의 파란 곡선은 둘째 줄, 30의 빨간 곡선은 셋째 줄에 해당한다

○ 세로축 눈금을 확인한다

- 손실이 237에서 4까지 내려간 곡선과 4.1에서 4.0으로 내려간 곡선은 모양이 비슷하게 보일 수 있다
- 눈금을 보지 않고 모양만 보면 잘못 읽는다

- 값의 규모 차이가 크면 세로축을 로그 눈금으로 바꾼다

○ **도달할 수 있는 바닥이 어디인지 안다면 같이 그린다**

- 잡음이 섞인 데이터에서는 손실이 0까지 내려가지 않는다. 실습 6.2의 바닥도 0이 아니라 0.2542다
- 실습 6.2는 도달할 수 있는 가장 낮은 손실을 미리 계산해 가로 점선으로 그렸다
- 곡선이 그 선에 붙으면 더 내려갈 곳이 없다는 뜻이다

---

7. 직접 움직여 보는 웹 자료

아래 설명은 각 페이지를 열어 확인한 내용이다. 모두 무료다.

자료	무엇을 볼 수 있는가	주소
Google 머신러닝 단기집중과정(한국어), 로지스틱 회귀: 손실 및 정규화	로지스틱 회귀의 손실로 제곱 손실 대신 로그 손실(교차 엔트로피)을 쓴다고 설명하고, 로그 손실 수식을 싣는다. 시그모이드 출력이 1에 가까워질수록 필요한 자릿수가 늘어나는 표가 있다	https://developers.google.com/machine-learning/crash-course/logistic-regression/loss-regularization?hl=ko
Google 머신러닝 단기집중과정(한국어), 손실	회귀의 손실을 다룬다. L1·L2와 MAE·MSE를 표로 구분하고, 이상치 하나가 MSE와 MAE에 다르게 작용하는 그림 두 장이 있다	https://developers.google.com/machine-learning/crash-course/linear-regression/loss?hl=ko
Google 머신러닝 단기집중과정(한국어), 경사하강법	반복 과정을 나타낸 도식, 1000번째 반복 근처에서 수렴하는 손실 곡선, 학습 시작·중간·끝의 모델 스냅샷 세 장, 3차원 손실 표면 그림이 있다	https://developers.google.com/machine-learning/crash-course/linear-regression/gradient-descent?hl=ko
Google 머신러닝 단기집중과정(한국어), 초매개변수	학습률·배치 크기·에포크를 각각 정의하고, 학습률이 알맞을 때·너무 작을 때·너무 클 때의 손실 곡선 네 장을 나란히 보여준다. 객관식 점검 문제 두 개가 붙어 있다	https://developers.google.com/machine-learning/crash-course/linear-regression/hyperparameters?hl=ko
TensorFlow Playground	학습률을 0.00001부터 10까지 목록에서 고르고, 배치 크기를 조절하고, 에포크를 재생·정지하며 Training loss와 Test loss가 변하는 것을 본다	https://playground.tensorflow.org/

○ 네 번째 자료의 그림 네 장은 실습 6.2와 짝이 된다. 우리가 만든 곡선과 나란히 놓고 모양을 비교한다

과제 (LMS 제출)

수업 시간에 실습을 실행했는지만 확인한다. 따로 보고서를 쓰지 않는다.

제출물

실습 6.2를 실행하면 만들어지는 학습률별 손실 곡선 그림 한 장을 LMS에 올린다.

- `practice/chapter6/results/learning_rate_curves.png`

평가 기준

- 파일을 올리면 완료로 인정한다. 손실이 얼마나 내려갔는지는 채점하지 않는다
- 해 보기에서 `LEARNING_RATES`나 `N_EPOCHS`를 바꿨다면 바뀐 그림이 올라온다. 기본값 그대로여도 인정한다

마감

- 실습 수업일 포함 7일 이내

핵심 정리

개념	한 줄 정리
손실	지금 모델이 얼마나 틀렸는지를 나타내는 숫자 하나. 작을수록 좋다
손실함수	그 숫자를 만드는 계산. 분류에서는 교차 엔트로피, 회귀에서는 평균제곱오차를 많이 쓴다
교차 엔트로피	정답 쪽에 준 확률 p에 –log를 씌운다. 확신하고 틀릴수록 끝없이 커진다. 숫자 분류와 언어모델도 이 손실로 학습한다
평균제곱오차	회귀의 손실. 정답과 예측의 차이를 제곱해 평균 낸다
기울기	어느 쪽으로 가야 손실이 줄어드는지 알려주는 화살표. 반대 방향으로 간다
경사하강법	새 w = 지금 w – 학습률 × 기울기. 이 한 줄을 반복한다
역전파	순전파로 값을 계산한 뒤, 출력에서 입력 쪽으로 "뒤에서 받은 값 × 이 칸에서 곱한 수"를 이어 가며 가중치마다 기울기를 구한다. 시그모이드와 교차 엔트로피의 맨 끝 값은 p – 정답이다
학습률	한 걸음의 보폭. 사람이 정한다. 작으면 진도가 안 나가고, 크면 손실이 처음보다 커지거나 오르내린다
epoch	전체 데이터를 한 번 다 본 것
batch	갱신 한 번 전에 묶어서 보는 데이터 개수. 갱신 횟수 = 데이터 수 ÷ 배치 크기 × 에포크
학습 곡선	에포크별 손실 그림. 모양을 보고 학습률을 어느 쪽으로 고칠지 정한다

다음 장에서는 손실을 끝까지 낮춘 모델이 오히려 새 데이터에서 틀리는 현상을 다룬다. 훈련 손실만 보면 안 되는 이유가 거기서 드러난다.