제9장 이미지 인식과 CNN — 컴퓨터가 이미지를 보는 방식

학습 목표

- 이미지 한 장이 컴퓨터에게 어떤 숫자 덩어리인지 설명한다
- 픽셀과 채널을 구분하고, 흑백 이미지와 컬러 이미지가 숫자 판 몇 장인지 말한다
- 이미지를 한 줄로 펴서 넣으면 무엇이 사라지는지 실험 결과로 설명한다
- 3x3 필터로 합성곱을 손으로 한 칸 계산한다
- 풀링(pooling)이 특징맵 크기를 어떻게 줄이는지 설명한다
- CNN의 층 순서를 그리고, 필터의 숫자를 학습으로 찾는다는 뜻을 설명한다
- 컴퓨터 비전의 대표 작업과 발전 과정을 설명한다

지금까지 다룬 데이터는 표였다. 가로줄 하나가 학생 한 명이었고, 세로줄 하나가 공부 시간이나 수면 시간 같은 특징이었다. 이번 장에서는 이미지를 다룬다. 이미지도 결국 숫자지만, 표와 달리 숫자가 **어느 칸에 놓였는지**에 뜻이 있다. 합성곱은 칸의 위치 관계를 살려서 계산하는 방법이고, 합성곱을 층으로 쌓은 신경망이 CNN이다.

이 장은 문제를 먼저 측정하고 해법을 뒤에 둔다. 1~3절에서 이미지를 숫자로 보고 한 줄로 펴서 넣는 방식을 설명한 뒤, 실습 9.1에서 그 방식으로 분류기를 만들어 어디까지 되고 어디서 무너지는지 측정한다. 4절에서 합성곱을 설명하고, 5절에서는 이 계산을 층으로 쌓은 CNN의 구조를 그림으로 보고, 6절에서는 CNN이 쓰이는 컴퓨터 비전 분야를 살펴본다.

○ 합성곱을 직접 계산하는 이유

- 딥러닝 라이브러리는 합성곱을 함수 하나로 계산해 주므로, 안에서 무슨 일이 일어나는지 보이지 않는다
- 4절은 창 하나의 합성곱을 곱셈 아홉 개까지 풀어 보여 준다. 그래서 필터의 숫자가 결과를 어떻게 만드는지 칸 단위로 따라갈 수 있다

실행 환경

```
cd practice/chapter9
python -m pip install -r ../requirements.txt
```

필요한 패키지는 numpy, pandas, matplotlib, scikit-learn이다. GPU는 필요 없다. 실습은 노트북에서 몇 초 안에 끝난다.

실습 데이터는 `sklearn.datasets.load_digits()`다. 합성 데이터가 아니라 실제 손글씨를 스캔해 만든 공개 데이터이고, scikit-learn 안에 들어 있어서 따로 내려받지 않는다.

1. 이미지는 숫자다

이미지 파일을 열면 사람은 그림을 보고, 컴퓨터는 숫자를 받는다. 이 장에서 쓰는 데이터는 손글씨 숫자 이미지이고, 한 장의 크기는 8 x 8 픽셀이다.

```
scikit-learn load_digits() - 실제 손글씨를 스캔해 만든 공개 데이터
이미지 장수: 1797장
이미지 한 장의 크기: 8 x 8 픽셀
채널 수: 1 (흑백이므로 숫자 판이 한 장이다)
픽셀값 범위: 0 ~ 16
이미지 한 장이 숫자 64개다
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

17번 이미지의 픽셀값을 그대로 찍으면 다음과 같다.

```
        0    1    2    3    4    5    6    7
    ----------------------------------------
0 |    0    0    1    8   15   10    0    0
1 |    0    3   13   15   14   14    0    0
2 |    0    5   10    0   10   12    0    0
3 |    0    0    3    5   15   10    2    0
4 |    0    0   16   16   16   16   12    0
5 |    0    1    8   12   14    8    3    0
6 |    0    0    0   10   13    0    0    0
7 |    0    0    0   11    9    0    0    0
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

이 숫자 64개가 이미지의 전부다. 0이 검정이고 16이 흰색이다. 4번 줄에서 16이 네 번 이어지는 칸이 밝은 가로획이다. 이 이미지의 정답은 7이다.

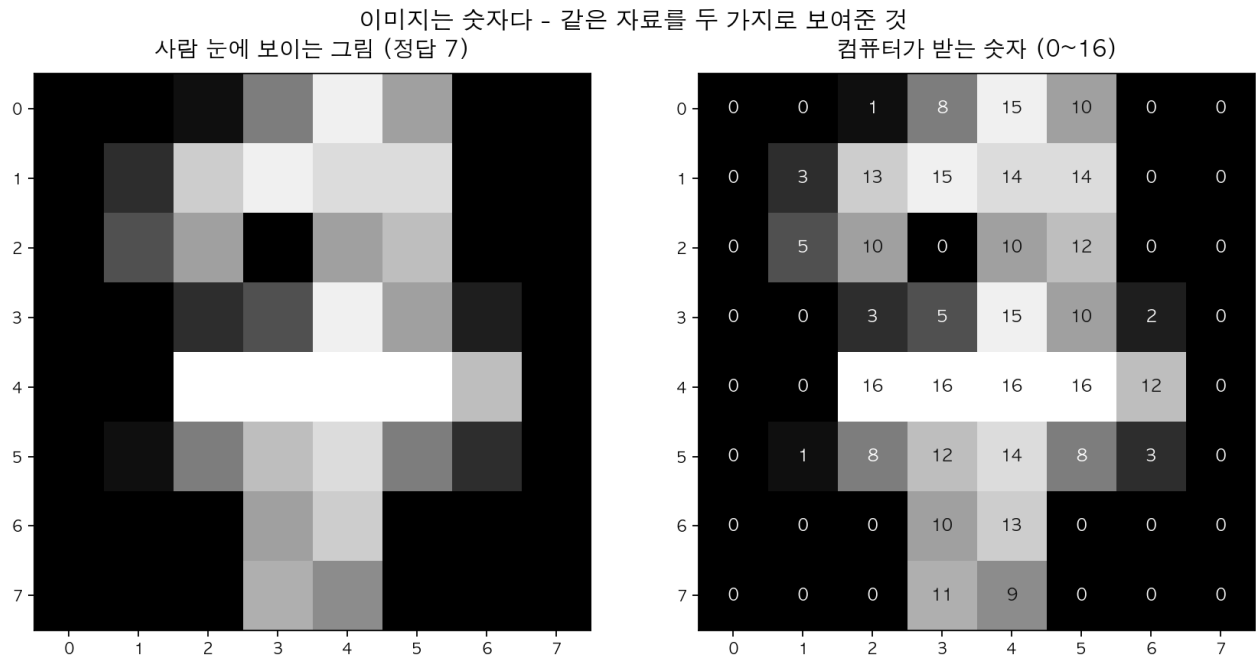


그림 9.1 왼쪽과 오른쪽은 같은 자료다. 사람은 왼쪽을 보고, 컴퓨터는 오른쪽을 받는다

○ **여기서 확인할 것**

- 사람이 "7처럼 생겼다"고 느끼는 그림과 컴퓨터가 받는 숫자 64개는 같은 자료다
- 밝기 차이가 곧 숫자 차이다. 획이 지나간 칸은 값이 크고, 배경 칸은 0이다

---

2. 픽셀과 채널

○ **픽셀(pixel)** — 이미지를 이루는 가장 작은 칸 하나

- 8 x 8 이미지에는 픽셀이 64개 있다
- 흑백 이미지에서 픽셀 하나는 밝기를 뜻하는 숫자 하나다

○ **채널(channel)** — 같은 크기의 숫자 판이 몇 장 겹쳐 있는가

- 흑백은 판이 한 장이므로 채널 수가 1이다
- 컬러는 빨강·초록·파랑 판이 한 장씩 있어서 채널 수가 3이다

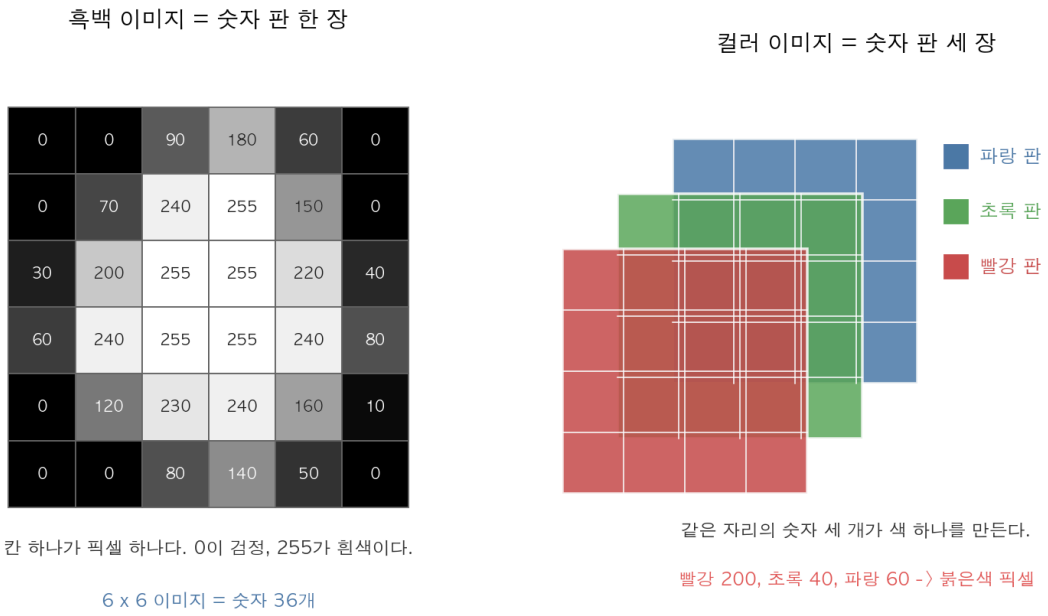


그림 9.2 같은 위치에 있는 세 판의 숫자 세 개가 색 하나를 만든다

컬러 이미지에서 픽셀 하나의 색을 알려면 숫자를 세 개 봐야 한다. 빨강 판에서 200, 초록 판에서 40, 파랑 판에서 60이면 그 픽셀은 붉은색이다.

이미지가 커지면 숫자 개수는 가로 × 세로 × 채널 수만큼 늘어난다.

표 9.1 이미지 크기와 숫자 개수

이미지	채널	숫자 개수
8 x 8 흑백 (실습 데이터)	1	64
28 x 28 흑백	1	784
200 x 200 컬러	3	120,000
1000 x 1000 컬러	3	3,000,000

---

3. 한 줄로 펴서 넣으면 무엇이 사라지는가

5장에서 만든 신경망은 입력을 한 줄로 받았다. 이미지를 그 신경망에 넣으려면 8 x 8을 한 줄로 펴야 한다. 위 줄부터 차례로 이어 붙이면 숫자 64개짜리 한 줄이 된다. 이 작업을 **평탄화**(flatten)라고 부른다.

○ **영상으로 먼저 보기** — [딥러닝 프로젝트] 1강. 합성곱 신경망(CNN) (한빛미디어, 약 11분)

- 주소: https://www.youtube.com/watch?v=hSUOpeUKqrM
- 영상 설명란의 목차는 00:43 인공 신경망, 03:45 합성곱 신경망, 09:47 풀링층이다
- 3절에서는 00:43의 인공 신경망 부분을, 4절을 읽은 뒤에는 03:45 이후를 이어서 본다

3-1. 위아래 이웃이 8칸 떨어진다

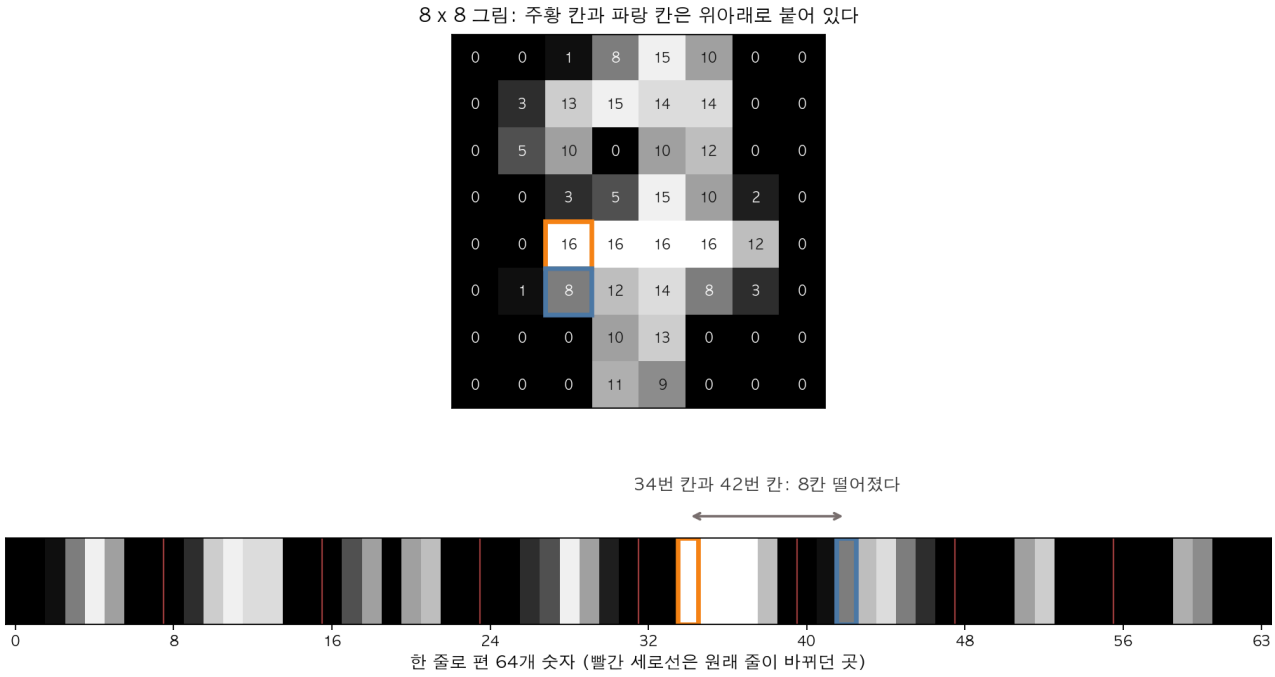


그림 9.3 주황 칸(4행 2열, 값 16)과 파랑 칸(5행 2열, 값 8)은 그림에서 위아래로 붙어 있다. 한 줄로 펴면 34번과 42번 자리로 가서 8칸 떨어진다

```
그림에서 위아래로 붙은 두 칸: (4행 2열, 값 16)과 (5행 2열, 값 8)
한 줄로 편 뒤의 자리: 34번과 42번 -> 8칸 떨어진다
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

가로로 붙은 두 칸은 한 줄에서도 붙어 있다. 위아래로 붙은 두 칸은 한 줄이 8칸이라서 8칸 떨어진다. 그림에서는 같은 획에 속한 두 칸이 한 줄에서는 멀리 놓인다.

3-2. 평탄화 모델은 칸 번호만 안다

평탄화 모델은 64칸을 0번부터 63번까지 번호로만 구별하고, 번호마다 가중치를 따로 둔다. "34번과 42번은 그림에서 위아래 이웃이다"라는 정보는 모델 어디에도 없다. 여기서 세 가지 결과를 예상할 수 있다.

○ 예측 1: 칸 순서를 섞어도 정확도가 거의 같다

- 모든 이미지의 칸 순서를 똑같이 섞으면 번호만 바뀌고 값은 그대로 남는다
- 모델은 바뀐 번호에 맞춰 가중치를 배운다. 사람은 섞인 그림을 알아볼 수 없지만 모델에게는 차이가 없다

○ 예측 2: 그림을 한 칸 밀면 정확도가 무너진다

- 7을 오른쪽으로 한 칸 옮겨 써도 사람 눈에는 같은 7이다
- 모델에게는 번호마다 들어오는 값이 바뀐다. 17번 이미지에서 34번 칸은 획의 밝기 16을 받았는데, 한 칸 밀면 배경의 0을 받는다

○ **문제 3: 이미지가 커지면 가중치가 너무 많아진다**

- 첫 층 뉴런 하나가 모든 칸과 연결되므로, 가중치 수는 입력 숫자 수 × 뉴런 수다
- 8 x 8 흑백에 뉴런 32개(실습 9.1의 모델)이면 64 × 32 = 2,048개다
- 200 x 200 컬러에 뉴런 100개이면 120,000 × 100 = 12,000,000개다

○ **바로 다음 실습 9.1의 설정**

- 1797장을 훈련 1257장과 테스트 540장으로 나누고, 8 x 8을 편 64개 숫자로 숫자 0~9를 분류한다
- 정확도와 자주 헷갈린 짝을 본 뒤, 예측 1과 예측 2를 실험으로 확인한다
- 실험 1은 64칸의 순서를 섞어 모델을 새로 학습한다. 실험 2는 학습이 끝난 모델에 한두 칸 민 테스트 이미지를 넣는다

실습 9.1: 64개 숫자로 분류하고 한계를 측정한다

실습 목표

- 8 x 8을 한 줄로 편 64개 숫자로 숫자 0~9를 분류하고, 기준선과 비교한다
- 틀린 이미지를 모아 실패 갤러리를 만들고, 어떤 짝이 자주 헷갈리는지 찾는다
- 칸 순서를 섞었을 때와 그림을 밀었을 때 정확도가 어떻게 달라지는지 측정한다

데이터와 모델

`load_digits()` 1797장이다. 모델은 scikit-learn의 `MLPClassifier`이고, 은닉층이 하나인 신경망이다. **CNN이 아니다.** 합성곱 층이 없다.

모델을 만드는 코드는 다음 한 줄이다.

```
MLPClassifier(hidden_layer_sizes=(32,), max_iter=60, random_state=42)
```

○ **은닉층(hidden layer)이란**

- 입력(숫자 64개)과 출력(숫자 0~9의 점수 10개) 사이에 있는 층이다. 입력과 출력은 우리가 정하는 값이고, 그 사이의 계산은 모델이 알아서 하므로 밖에서 보이지 않는다는 뜻에서 은닉(hidden, 숨겨진)이라고 부른다
- 은닉층의 뉴런 하나는 앞 층의 숫자를 전부 받아 하나씩 가중치를 곱해 더한 값 하나를 내보낸다

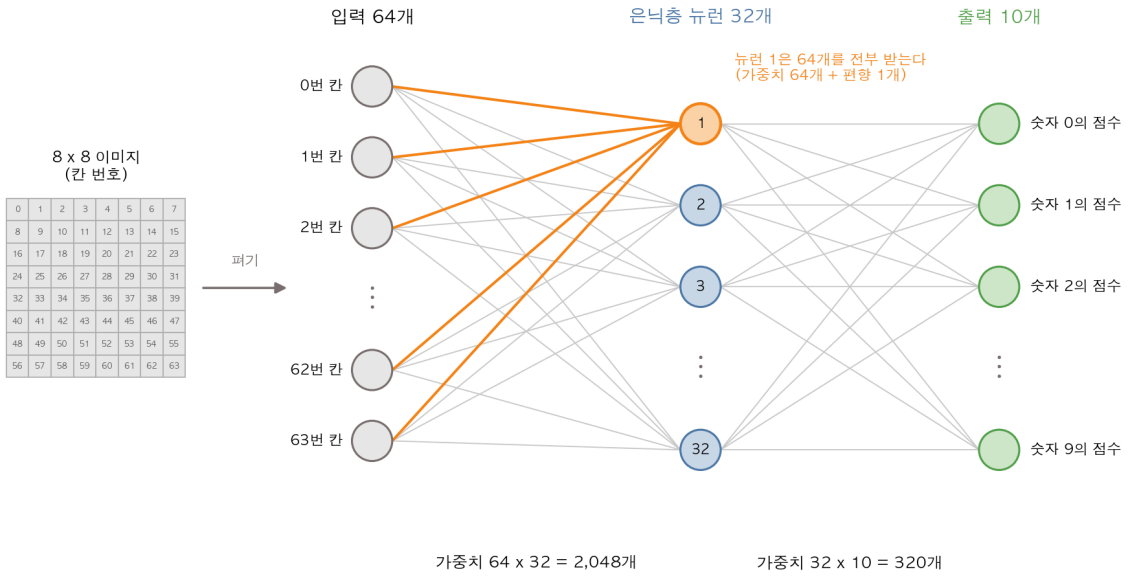
○ **`hidden_layer_sizes=(32,)`를 읽는 법**

- 괄호 안의 숫자 하나가 은닉층 하나이고, 숫자의 크기가 그 층의 뉴런 수다. `(32,)`는 "은닉층 1개, 뉴런 32개"다. 숫자가 하나뿐이어도 쉼표를 붙이는 것은 파이썬에서 원소가 하나인 묶음을 쓰는 규칙이다
- `(64, 32)`라고 쓰면 은닉층이 2개이고 뉴런 수가 64개, 32개다. 숫자를 늘리면 층이 깊어지고, 숫자를 키우면 층이 넓어진다

○ **이 모델의 크기를 숫자로 보면**

- 층별 뉴런 수는 입력 64 → 은닉 32 → 출력 10이다
- 연결마다 가중치가 있다. 입력과 은닉층 사이는 64 × 32 = 2,048개, 은닉층과 출력 사이는 32 × 10 = 320개다. 뉴런마다 따로 더하는 값(편향)이 은닉층 32개, 출력층 10개 있어서 학습으로 정하는 숫자는 모두 2,410개다
- 은닉층 뉴런 수를 바꾸면 이 개수가 바뀐다. 뉴런이 늘수록 모델이 만들 수 있는 모양이 다양해지고, 가중치도 그만큼 늘어난다. 7장 표 7.3에서 신경망의 복잡도 손잡이가 층 수와 뉴런 수라고 한 것이 이 값이다

그림 9.4는 이 모델을 층마다 몇 개만 골라 그린 것이다. 노드 106개를 모두 그리면 선이 겹쳐 읽을 수 없으므로 나머지는 점 세 개로 줄였다.



층마다 일부만 그린 개념 도식이다. 입력 64개 중 5개, 은닉층 32개 중 4개, 출력 10개 중 4개를 그렸다.

그림 9.4 실습 9.1 모델의 일부. 입력 64개 중 5개, 은닉층 뉴런 32개 중 4개, 출력 10개 중 4개만 그렸다. 주황 선은 은닉층 뉴런 1이 받는 연결이다

실행 명령

```
cd practice/chapter9/code
python 9-1-flatten-classifier.py
```

핵심 코드

파일 맨 위에 바꿀 값이 다섯 개 있다.

```
SAMPLE_INDEX = 17       # 픽셀 표로 볼 손글씨 번호. 0부터 1796까지 넣을 수 있다.
HIDDEN_SIZE = 32        # 은닉층 뉴런 수. 크게 하면 정확도가 오르지만 느려진다.
MAX_ITER = 60           # 학습을 몇 바퀴 돌 것인가.
TEST_RATIO = 0.3        # 테스트로 떼어 둘 비율
GALLERY_SIZE = 12       # 실패 갤러리에 넣을 이미지 장수
```

`HIDDEN_SIZE`는 코드 안에서 `hidden_layer_sizes=(HIDDEN_SIZE,)`로 들어간다. 이 값을 32에서 128로 바꾸면 입력과 은닉층 사이의 가중치는 64 × 128 = 8,192개가 된다.

실험 1은 64칸의 순서를 한 번 정해 훈련과 테스트 모두에 똑같이 적용한 뒤 새로 학습한다.

```
perm = np.random.default_rng(RANDOM_SEED).permutation(x.shape[1])
model_perm.fit(x_train[:, perm], y_train)
perm_acc = accuracy_score(y_test, model_perm.predict(x_test[:, perm]))
```

실험 2는 다시 학습하지 않는다. 테스트 이미지만 밀어서 원래 모델에 넣는다. 비는 칸은 0(검정)으로 채운다.

```
shifted = shift_images(img_test, dx, dy)
acc = accuracy_score(y_test, model.predict(flatten(shifted)))
```

전체 코드는 `practice/chapter9/code/9-1-flatten-classifier.py` 참고

실행 결과

```
전체 1797장 = 훈련 1257장 + 테스트 540장
입력: 8x8 이미지를 한 줄로 펴서 숫자 64개

기준선(가장 많은 숫자로만 답하기)              0.102
훈련 데이터                                  0.960
테스트 데이터                                 0.933
학습 반복 실제 횟수: 60회

테스트 540장 중 틀린 것 36장
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

```
hidden_layer_sizes = (32,)
층별 뉴런 수: 64 -> 32 -> 10  (입력 -> 은닉층 -> 출력)
1번째 연결: 가중치 64 x 32 = 2048개, 편향 32개
2번째 연결: 가중치 32 x 10 = 320개, 편향 10개
가중치와 편향을 합한 전체 개수: 2410개
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

```
=== 실험 1. 64칸의 순서를 섞어 새로 학습 ===
원래 순서로 학습                0.933
섞은 순서로 학습                0.943
차이: +0.009

=== 실험 2. 테스트 이미지를 밀어서 넣기 (다시 학습하지 않는다) ===
조건                      테스트 정확도
원본                        0.933
오른쪽 1칸                  0.439
왼쪽 1칸                    0.376
아래 1칸                    0.470
오른쪽 2칸                  0.152
기준선: 0.102
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

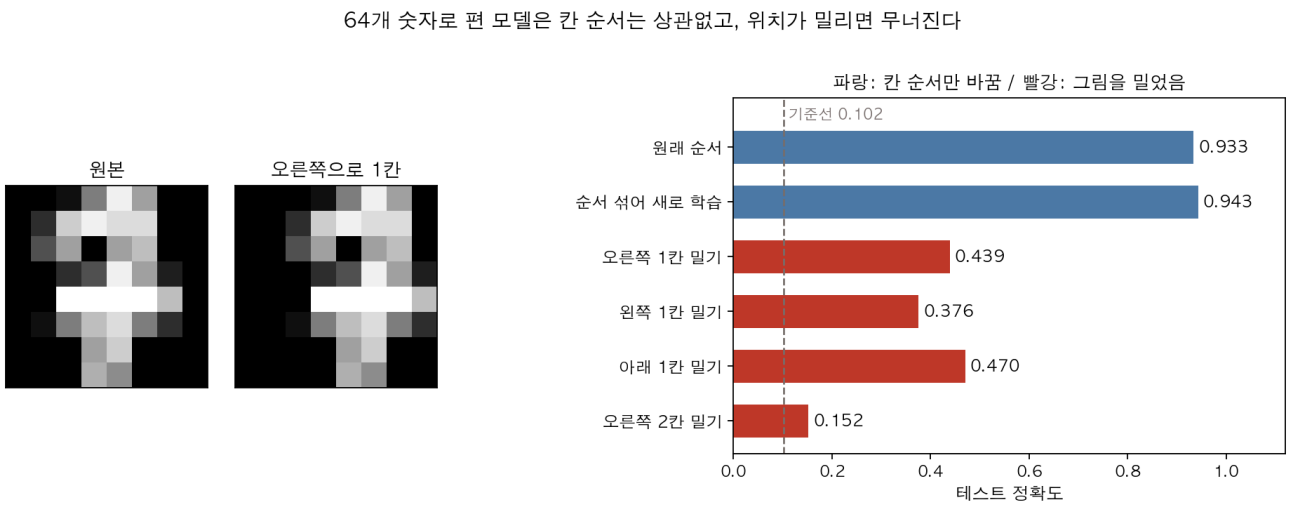


그림 9.5 왼쪽은 원본과 오른쪽으로 1칸 민 이미지다. 오른쪽 막대에서 파랑은 칸 순서만 바꾼 경우, 빨강은 그림을 민 경우의 테스트 정확도다. 점선은 기준선이다

표 9.2 자주 헷갈린 짝 (테스트 540장 기준)

정답	모델 예측	건수
8	1	8
9	7	4
1	9	4
1	8	4
5	9	3
2	1	2

출처: `practice/chapter9/results/9-1-flatten-classifier.log`



그림 9.6 실패 갤러리. 각 그림 위에 정답과 모델의 예측을 적었다

결과 읽기

○ 평탄화해도 0.933까지 맞힌다

- 기준선 0.102는 가장 많은 숫자 하나로만 답했을 때의 정확도다. 정답이 열 가지이고 개수가 고르므로 10분의 1 근처가 나온다
- 테스트 0.933은 기준선의 아홉 배가 넘는다. 3절의 문제가 있어도 이 데이터에서 평탄화 모델이 쓸모없지는 않다
- 훈련 0.960과 테스트 0.933의 차이는 0.027이다. 7장에서 본 과적합의 간격이 작은 경우다

○ 예측 1이 맞았다: 순서를 섞어도 정확도가 거의 같다

- 원래 순서 0.933, 섞은 순서 0.943이다. 섞은 쪽이 오히려 조금 높다
- 두 값이 완전히 같지 않은 이유는 학습 시작 때 가중치를 무작위로 정하기 때문이다. 같은 seed라도 칸 번호가 바뀌면 각 칸에 배정되는 처음 가중치가 달라진다
- 이 결과는 평탄화 모델이 "어느 칸이 어느 칸 옆인가"를 쓰지 않는다는 증거다. 쓰고 있었다면 순서를 섞은 뒤 성능이 떨어졌어야 한다

○ 예측 2도 맞았다: 한 칸만 밀어도 정확도가 반 아래로 떨어진다

- 오른쪽 1칸에서 0.439, 왼쪽 1칸에서 0.376, 아래 1칸에서 0.470이다. 원본 0.933의 절반에도 못 미친다
- 오른쪽 2칸이면 0.152로 기준선 0.102에 가까워진다
- 밀어서 잘려 나간 밝기는 원인이 아니다. 오른쪽 1칸 밀 때 잘려 나간 밝기 합은 이미지 한 장 평균 1.1이고, 전체 밝기 합 평균은 312.2다. 획은 거의 그대로 남았고 위치만 바뀌었다

○ 틀린 이미지에는 규칙이 있다

- 8을 1로 본 것이 8건으로 가장 많다. 그림 9.6의 두 번째 줄 두 번째 그림이 그 예다. 8 x 8까지 줄인 8은 가운데 세로 획만 굵게 남는 경우가 있다
- 1·8·9·7이 서로 섞인다. 1을 9로 4건, 1을 8로 4건, 9를 7로 4건 틀렸다. 네 숫자 모두 가운데에 긴 세로 획이 있다
- 표 9.2에서 보듯 틀린 건수는 특정 짝에 몰려 있다. 정확도 0.933이라는 숫자 하나로는 이 사실이 보이지 않는다. 4장에서 혼동행렬을 배운 이유가 여기서 다시 나온다

학습 중 나온 경고

로그에 경고가 하나 찍힌다. 지우지 않고 그대로 뒀다.

```
[ConvergenceWarning] Stochastic Optimizer: Maximum iterations (60) reached and the optimiza
```

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

`MAX_ITER = 60`으로 작게 잡아서 나온 경고다. 학습이 아직 끝나지 않았는데 반복 횟수를 다 썼다는 뜻이다. 수업 시간 안에 끝나는 것을 우선해 이 값을 작게 뒀다.

해 보기

1. `SAMPLE_INDEX`를 0, 1, 2로 바꿔 다른 숫자의 픽셀 표를 본다. 0과 1은 숫자 64개의 배치가 어떻게 다른가
2. `MAX_ITER`를 300으로 올린다. 경고가 사라지는가. 원본 정확도와 1칸 민 정확도는 각각 얼마가 되는가
3. `HIDDEN_SIZE`를 128로 올린다. 모델을 키우면 1칸 민 이미지의 정확도도 회복되는가
4. `GALLERY_SIZE`를 20으로 올려 실패 갤러리를 넓게 본다. 8을 1로 본 이미지가 몇 장 들어오는가

○ 2번과 3번은 같은 질문이다. **학습을 더 하거나 모델을 키우는 것으로 위치 문제가 풀리는가.** 결과를 확인한 뒤 4절로 넘어간다

---

4. 합성곱 신경망(CNN)의 계산

평탄화 모델은 칸 번호마다 따로 가중치를 배운다. 그래서 실습 9.1에서 그림을 한 칸 밀자 정확도가 0.933에서 0.439로 떨어졌다. **합성곱 신경망**(Convolutional Neural Network, CNN)은 작은 필터 하나를 이미지의 모든 위치에 같은 방식으로 적용한다. CNN의 핵심은 **어떤 필터를 쓸지를 사람이 정하지 않고 학습으로 찾는다**는 데 있다.

4-1. 합성곱 연산

필터(filter, 커널이라고도 부른다)는 3 x 3이나 5 x 5 크기의 작은 숫자 판이다. **합성곱**(convolution)은 필터를 이미지 위에 겹쳐 놓고, 겹친 숫자끼리 곱해서 전부 더하는 계산이다.

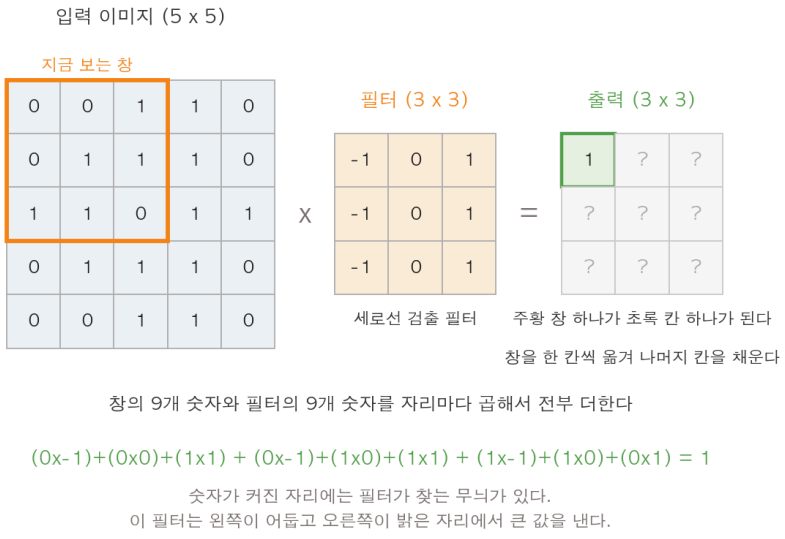


그림 9.7 주황 창 안의 숫자 아홉 개와 필터의 숫자 아홉 개를 위치마다 곱해 더하면, 출력 칸 하나가 채워진다. 그림의 5 x 5 입력은 설명용으로 손으로 고른 값이다

1. 이미지 왼쪽 위에서 필터 크기만 한 창을 하나 떼어 낸다
2. 창의 숫자와 필터의 숫자를 **위치마다** 곱한 뒤 전부 더한다

3. 그 합을 출력 칸 하나에 적고, 창을 옆으로 옮겨 반복한다

아래는 1절의 17번 이미지에서 2행 2열부터 시작하는 창에 세로선 필터를 씌운 결과다.

```
이미지 창          필터              곱한 값
  10    0   10   x   -1.0   0.0   1.0   =   -10.0    0.0   10.0
   3    5   15   x   -1.0   0.0   1.0   =    -3.0    0.0   15.0
  16   16   16   x   -1.0   0.0   1.0   =   -16.0    0.0   16.0

더하기: (10x-1) + (0x0) + (10x1) + (3x-1) + (5x0) + (15x1) + (16x-1) + (16x0) + (16x1)
      = 12.0
```

출처: `practice/chapter9/results/9-2-filter-and-pooling.log`

4-2. 특징맵

창을 왼쪽 위에서 오른쪽으로 한 칸씩 옮기고, 줄 끝에 닿으면 한 줄 내려가 다시 옮긴다. 창 하나가 출력 칸 하나를 채우며, 이렇게 채운 출력 판을 **특징맵**(feature map)이라 부른다. 필터가 찾는 무늬가 있는 곳에서 특징맵의 값이 커진다.

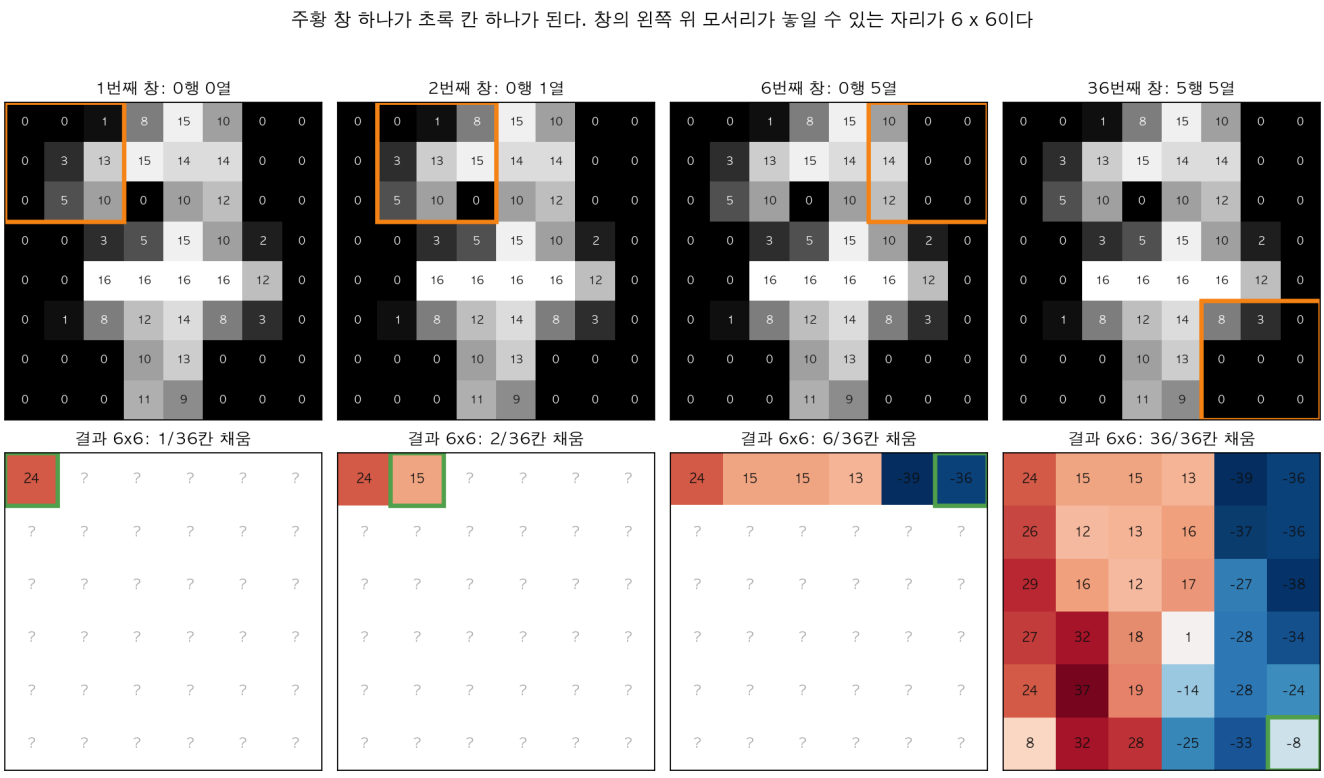


그림 9.8 윗줄의 주황 창 하나가 아랫줄의 초록 칸 하나가 된다. 1번째·2번째·6번째·36번째 창을 골라 그렸다

○ 창이 이미지 밖으로 나가지 않으면 `출력 크기 = 입력 크기 - 필터 크기 + 1`이다. 8 x 8에 3 x 3 필터를 쓰면 8 - 3 + 1 = 6이므로 특징맵은 6 x 6이다

○ 36개 위치 모두에 같은 필터를 쓴다. 무늬가 옮겨 가면 특징맵에서 큰 값이 나오는 칸도 함께 옮겨 간다. 이미지가 커져도 필터의 숫자는 아홉 개 그대로다

4-3. 합성곱 뒤의 ReLU

합성곱 결과에는 음수도 나온다. CNN은 특징맵에 5장에서 본 ReLU를 적용해 음수를 0으로 바꾸고 양수는 그대로 둔다. 그러면 필터가 찾는 무늬가 있는 칸의 값만 남는다.

4-4. 보폭과 패딩

○ **보폭**(stride) — 창을 한 번에 옮기는 칸 수다. 보폭이 1이면 한 칸씩, 2이면 한 칸씩 건너뛰며 옮긴다. 보폭을 키우면 특징맵이 작아진다

○ **패딩**(padding) — 이미지 가장자리를 처리하는 방법이다. 두 가지를 쓴다

- **valid**: 창을 이미지 안에서만 움직인다. 특징맵이 입력보다 작아진다(8 x 8 → 6 x 6)
- **same**: 이미지 둘레를 0 같은 값으로 채운 뒤 계산해서, 특징맵을 입력과 같은 크기로 맞춘다

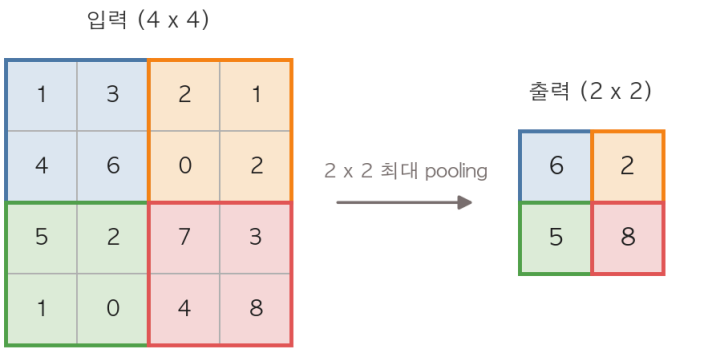
이 장의 계산은 보폭 1, valid다.

4-5. 필터가 여러 개일 때

필터 하나는 특징맵 한 장을 만든다. 필터를 4개 쓰면 같은 이미지에서 특징맵 4장이 나온다. 필터마다 숫자가 다르므로 세로선, 가로선처럼 서로 다른 무늬를 찾는다.

4-6. 풀링

풀링(pooling)은 특징맵의 크기를 줄이는 계산이다. 가장 많이 쓰는 **최대 풀링**(max pooling)은 겹치지 않는 2 x 2 덩어리마다 가장 큰 값 하나만 남긴다.



덩어리마다 가장 큰 숫자 하나만 남긴다. 숫자 16개가 4개로 줄었다.

파란 덩어리의 1, 3, 4, 6 중에서 6을 고른다

자리가 한두 칸 흔들려도 가장 큰 값은 잘 바뀌지 않는다.
그래서 pooling 뒤에는 위치가 조금 달라진 그림도 비슷한 숫자가 나온다.

그림 9.9 2 x 2 덩어리마다 최댓값 하나만 남긴다. 숫자 16개가 4개로 줄었다. 그림의 숫자는 설명용으로 손으로 고른 값이다

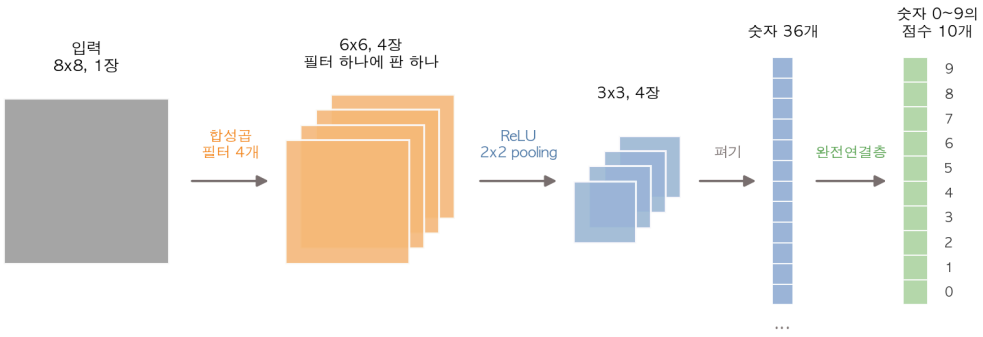
○ 6 x 6 특징맵에 2 x 2 풀링을 하면 3 x 3이 된다. 칸 수가 36에서 9로 줄어 뒤 층의 계산이 빨라진다

○ 강한 반응이 덩어리 안에서 한 칸 옮겨 가도 최댓값은 같다. 그래서 그림이 조금 움직여도 결과가 덜 바뀐다

---

5. CNN의 전체 구조

CNN은 합성곱층과 풀링층을 번갈아 쌓고, 마지막에 완전연결층을 둔다. 앞부분은 이미지에서 특징을 뽑고, 뒷부분은 뽑은 특징으로 분류한다.



판 크기는 8 -〉 6 -〉 3으로 줄고, 판 장수는 1 -〉 4로 는다. 학습으로 찾는 값은 필터 4개의 숫자 36개와 완전연결층의 가중치다.

이 그림은 층 순서와 판 크기를 보여 주는 개념 도식이다.

그림 9.10 8 x 8 입력에 필터 4개를 쓰는 작은 CNN의 개념 도식이다. 판의 크기는 8 → 6 → 3으로 줄고, 판의 장수는 1 → 4로 는다

```
8 x 8 입력 → 합성곱(필터 4개) → 6 x 6 특징맵 4장 → ReLU → 2 x 2 풀링 → 3 x 3 판 4장
          → 펴기 → 숫자 36개 → 완전연결층 → 숫자 0~9의 점수 10개
```

○ **합성곱층** — 필터 여러 개로 특징맵을 만들고 ReLU를 적용한다(4-1~4-5)

○ **풀링층** — 특징맵의 크기를 줄인다(4-6)

○ **펴기**(flatten) — 풀링층에서 나온 판 여러 장을 숫자 한 줄로 편다. 3 x 3 판 4장은 숫자 36개가 된다

○ **완전연결층** — 펴 놓은 숫자 전부를 받아 숫자 0~9의 점수를 낸다. 실습 9.1의 은닉층처럼 앞 층의 숫자를 전부 받아 가중치를 곱해 더하는 층이다

○ **학습** — 6장의 역전파로 손실을 줄이는 방향으로 가중치를 고친다. CNN에서 고치는 가중치는 합성곱층의 필터 숫자와 완전연결층의 가중치다. 4-1의 세로선 필터는 사람이 정했지만, CNN은 이 숫자를 데이터에서 찾는다

표 9.3 3절의 문제와 CNN이 쓰는 방법

평탄화 방식의 문제	실습에서 확인한 것	합성곱·풀링이 하는 일
칸 사이의 이웃 관계를 쓰지 않는다	순서를 섞어도 0.933 → 0.943	3 x 3 창으로 붙어 있는 칸끼리만 묶어 계산한다
위치가 밀리면 배운 것을 쓰지 못한다	1칸 밀면 0.933 → 0.439	같은 필터를 모든 위치에 쓰므로 결과가 그림과 함께 옮겨 가고, 풀링이 작은 이동을 지운다
이미지가 커지면 가중치가 폭증한다	8 x 8에서도 첫 층 가중치 2,048개	필터 하나의 숫자는 9개이고, 이미지가 커져도 그대로다

출처: `practice/chapter9/results/9-1-flatten-classifier.log`

표 9.3의 오른쪽 열은 합성곱과 풀링의 계산 구조에서 나오는 성질이며, 학습을 마친 CNN의 정확도로 확인한 값이 아니다. 실제 CNN 학습에는 PyTorch나 TensorFlow 같은 딥러닝 라이브러리를 쓴다.

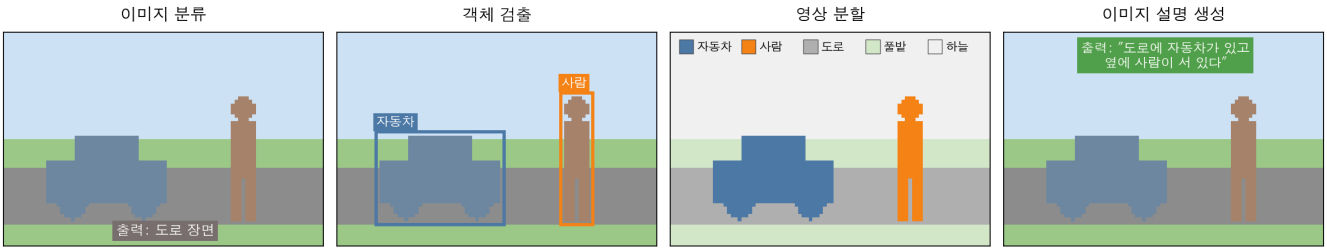
---

6. 컴퓨터 비전

컴퓨터 비전(computer vision)은 컴퓨터가 이미지와 영상에서 정보를 얻게 하는 분야다. 이 장에서 다룬 손글씨 숫자 분류도 컴퓨터 비전 문제이고, CNN은 이 분야에서 가장 널리 쓰인 모델이다.

6-1. 컴퓨터 비전이 하는 일

같은 사진을 넣어도 무엇을 출력하게 하느냐에 따라 작업이 달라진다.



같은 장면을 넣어도 작업에 따라 출력이 다르다. 장면은 설명용으로 손으로 그린 도형이다.

그림 9.11 같은 장면을 넣었을 때 네 작업이 내놓는 출력이다. 분류는 사진 전체에 이름표 하나, 검출은 물체마다 상자 하나, 분할은 픽셀마다 이름표 하나, 설명 생성은 문장 하나를 낸다. 장면은 설명용으로 손으로 그린 도형이다

표 9.4 컴퓨터 비전의 대표 작업

작업	컴퓨터가 내놓는 것	예
이미지 분류	이미지 한 장에 이름표 하나	손글씨 숫자 0~9 맞히기(실습 9.1)
객체 검출(object detection)	물체마다 위치를 표시한 상자와 이름표	도로 사진에서 자동차와 사람 찾기
영상 분할(segmentation)	픽셀마다 이름표	의료 영상에서 병변 영역 칠하기
이미지 설명 생성(captioning)	이미지를 설명하는 문장	사진을 보고 "공원에서 개가 뛰고 있다"라고 쓰기

이미지 설명 생성처럼 다른 신경망과 함께 쓰는 경우도 많다. 이미지를 읽는 일은 CNN이 맡고, 문장을 만드는 일은 순환 신경망 같은 문장용 모델이 맡는다. 바둑 프로그램 알파고도 바둑판을 19 x 19 이미지처럼 읽는 데 CNN을 썼다.